




دانشگاه صنعتی شریف
مرکز مهندسی کوانتوم و فناوری‌های فوتونیک
گروه الگوریتم و نرم‌افزار کوانتومی

گزارش فنی پروژه
مدل‌سازی نویز خوانش کوانتومی
و تولید دیتاست برای یادگیری ماشین
سیستم چهار کیوبیتی

استخراج ماتریس‌های نویز از داده‌های تجربی IQ
و اعمال نویز بر مدارهای کوانتومی

بہمن ۱۴۰۴

فهرست مطالب

۱	گزارش فنی پروژه نويز خوانش چهار کيوييتي	۱
۱	۱.۱ هدف و تصوير کلي	۱
۲	۲.۱ داده‌هاي تجربي IQ	۲
۲	۱.۲.۱ ساختار فايل‌ها	۲
۲	۲.۲.۱ برچسب‌گذاري و ترتيب بيت‌ها	۲
۳	۳.۲.۱ ابرهاي IQ و معنای فيزيکی آن‌ها	۳
۳	۳.۱ استخراج ماتريس‌هاي نويز خوانش	۳
۳	۱.۳.۱ مدل Linear Discriminant Analysis	۳
۴	۲.۳.۱ ماتريس‌هاي تک‌کيوييتي 2×2	۴
۵	۳.۳.۱ ماتريس همبسته 16×16	۵
۵	۴.۳.۱ چرا ماتريس 16×16 برابر کرونکر چهار ماتريس 2×2 نيست؟	۵
۶	۴.۱ مدارهاي کوانتومي استفاده‌شده در بخش دوم	۶
۶	۱.۴.۱ مدار مستقل Independent RY	۶
۸	۲.۴.۱ مدار ZZ FeatureMap	۸
۹	۵.۱ سه مدل نويز خوانش	۹
۹	۱.۵.۱ نويز مصنوعي	۹
۹	۲.۵.۱ نويز تجربي تک‌کيوييتي	۹
۹	۳.۵.۱ نويز تجربي همبسته	۹

۶.۱	تولید دیتاست و مدل یادگیری ماشین	۱۰
۱.۶.۱	خط لوله تولید دیتاست	۱۰
۲.۶.۱	مدل MLP	۱۱
۷.۱	معیار fidelity	۱۱
۱.۷.۱	تعریف و تفسیر	۱۱
۲.۷.۱	چرا fidelity معیار مناسبی است؟	۱۲
۸.۱	نتایج و تحلیل	۱۳
۱.۸.۱	جدول اصلی fidelity	۱۳
۲.۸.۱	تحلیل ردیف بدون آموزش	۱۳
۳.۸.۱	اهمیت همخوانی نويز آموزش و آزمون	۱۳
۴.۸.۱	وقتی نويز آموزش و آزمون متفاوت است	۱۴
۵.۸.۱	بهبود نسبت به baseline	۱۴
۹.۱	نکات حساس و توصیه‌های عملی	۱۵
۱۰.۱	جمع‌بندی نهایی	۱۵

فصل ۱

گزارش فنی پروژه نویز خوانش چهار کیوبیتی

۱.۱ هدف و تصویر کلی

هدف این گزارش، مستندسازی یک خط لوله کامل برای مدل‌سازی نویز خوانش در یک سامانه چهار کیوبیتی است. پروژه از داده‌های خام تجربی IQ شروع می‌شود، از روی آن‌ها ماتریس‌های خطای خوانش را استخراج می‌کند، سپس این نویزها را روی مدارهای کوانتومی اعمال می‌کند و در نهایت با یک مدل یادگیری ماشین تلاش می‌کند توزیع احتمال نویزی را به توزیع ایده‌آل بازگرداند.

دو فایل اصلی پروژه چنین نقشی دارند:

- `readout_matrix.ipynb`: بارگذاری داده‌های تجربی، آموزش تفکیک‌کننده IQ، استخراج ماتریس‌های 2×2 و 16×16 ؛

- `noisy_4q_zzfeaturemap.ipynb`: ساخت مدار، اعمال سه نوع نویز، تولید دیتاست، آموزش MLP و ارزیابی با `fidelity`.

در کل پروژه یک قرارداد مهم حفظ می‌شود: ماتریس نویز خوانش به صورت

$$A_{ij} = P(\text{measured} = j \mid \text{prepared} = i) \quad (1.1)$$

تعریف شده است. بنابراین سطرها حالت آماده‌سازی و ستون‌ها حالت اندازه‌گیری هستند و هر سطر جمع یک دارد. این همان قرارداد مورد استفاده در `Qiskit ReadoutError` است.

۲.۱ داده‌های تجربی IQ

۱.۲.۱ ساختار فایل‌ها

داده‌های تجربی در پوشه quadrature_data_4qubits قرار دارند. برای هر یک از ۱۶ حالت پایه محاسباتی یک فایل وجود دارد؛ از 0000.txt تا 1111.txt. هر فایل چهار خط دارد؛ هر خط مربوط به یک کیوبیت است و شامل ۱۰۰۰ نمونه مختلط از نوع

$$z = I + iQ$$

است. بنابراین برای هر حالت آماده‌سازی، ۱۰۰۰ shot و برای کل پروژه

$$16 \times 1000 = 16000$$

نمونه چهارکیوبیتی داریم. پس از بارگذاری:

$$X \in \mathbb{C}^{16000 \times 4}, \quad Y \in \{0, 1\}^{16000 \times 4}.$$

در این نمایش، $X[n, q]$ نمونه IQ کیوبیت q در shot شماره n و $Y[n, q]$ بیت آماده‌سازی همان کیوبیت است.

۲.۲.۱ برچسب‌گذاری و ترتیب بیت‌ها


برچسب‌ها از نام فایل به دست می‌آیند. در کد، تابع `bits_from_filename` نام فایل را خوانده و برای سازگاری با ترتیب داخلی پروژه، بیت‌ها را معکوس می‌کند. قرارداد اندیس‌گذاری حالت‌ها چنین است:

$$i = b_1 + 2b_2 + 4b_3 + 8b_4. \quad (۲.۱)$$

پس b_1 کم‌ارزش‌ترین بیت است و b_4 پرازش‌ترین بیت. این قرارداد باید در همه بخش‌ها، از ساخت ماتریس نویز تا تبدیل شمارش‌های Qiskit به بردار احتمال، یکسان بماند.

۳.۲.۱ ابرهای IQ و معنای فیزیکی آنها

در اندازه‌گیری dispersive، خروجی هر shot یک نقطه در صفحه IQ است. اگر کیوبیت در حالت $|0\rangle$ آماده شده باشد، نقاط باید اطراف یک ابر و اگر در $|1\rangle$ آماده شده باشد اطراف ابر دیگری قرار گیرند. هرچه این دو ابر جداتر باشند، fidelity readout بالاتر است. همپوشانی ابرها همان ناحیه‌ای است که در آن تفکیک‌کننده ممکن است 0 را 1 یا 1 را 0 تشخیص دهد.



شکل ۱.۱: ابرهای IQ برای دو حالت چهارکیوبیتی 1010 و 0101. هر پنل مربوط به یک کیوبیت است. جدایی و همپوشانی ابرها نشان می‌دهد خطای خوانش برای هر کیوبیت چقدر است و آیا crosstalk بین کیوبیت‌ها وجود دارد یا نه.

شکل ۱.۱ چند نکته مهم را نشان می‌دهد. نخست، جدایی ابرها برای همه کیوبیت‌ها یکسان نیست، پس ماتریس‌های تک‌کیوبیتی نباید الزاماً مشابه باشند. دوم، شکل ابرها فقط تابع بیت همان کیوبیت نیست و حالت کلی چهارکیوبیتی هم می‌تواند مرکز یا پراکندگی ابر را تغییر دهد. این رفتار نشانه‌ای از crosstalk و دلیل اصلی نیاز به ماتریس همبسته 16×16 است.

۳.۱ استخراج ماتریس‌های نویز خوانش

۱.۳.۱ مدل Linear Discriminant Analysis

در بخش اول پروژه، برای هر کیوبیت یک مدل LinearDiscriminantAnalysis یا LDA آموزش داده شده است. ورودی مدل برای کیوبیت q بردار دوبعدی

$$\mathbf{x} = (I, Q)^\top$$

و برجسب آن 0 یا 1 است. داده‌ها با train_test_split و نسبت 80/20 تقسیم می‌شوند و ویژگی‌ها قبل از آموزش با StandardScaler نرمال‌سازی می‌شوند.

LDA فرض می‌کند دو کلاس 0 و 1 در صفحه IQ تقریباً توزیع گاوسی با کواریانس مشترک دارند. برای کلاس k تابع امتیاز به صورت

$$\delta_k(\mathbf{x}) = \mathbf{x}^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log \pi_k \quad (3.1)$$

نوشته می‌شود. در این رابطه μ_k میانگین کلاس، Σ کواریانس مشترک و π_k prior کلاس است. مدل نمونه را به کلاسی نسبت می‌دهد که δ_k بزرگ‌تری دارد. برای دو کلاس، مرز تصمیم یک خط در صفحه IQ است:

$$\mathbf{w}^\top \mathbf{x} + w_0 = 0, \quad \mathbf{w} = \Sigma^{-1}(\mu_1 - \mu_0).$$

انتخاب LDA برای این پروژه منطقی است، چون مسئله تفکیک IQ دوبعدی است، مدل پایدار و قابل تفسیر است و هدف اصلی صرفاً بیشینه کردن accuracy نیست؛ هدف ساختن تخمینی پایدار از احتمال‌های $P(m|p)$ است. در نوت‌بوک، QDA نیز آزمایش شده است، اما LDA به عنوان گزینه ساده‌تر و پایدارتر انتخاب شده است.

۲.۳.۱ ماتریس‌های تک‌کیوبیتی 2×2

پس از آموزش مدل کیوبیت q ، خروجی model روی داده test با برچسب واقعی مقایسه می‌شود. ماتریس تخصیص تک‌کیوبیتی از ماتریس confusion نرمال شده ساخته می‌شود:

$$A^{(q)} = \begin{pmatrix} P(m_q = 0|p_q = 0) & P(m_q = 1|p_q = 0) \\ P(m_q = 0|p_q = 1) & P(m_q = 1|p_q = 1) \end{pmatrix}. \quad (4.1)$$

در این ماتریس، عناصر قطری fidelity خوانش حالت‌های 0 و 1 هستند و عناصر غیرقطری احتمال خطای flip در خوانش را نشان می‌دهند. برای مثال، در یکی از اجراها ماتریس کیوبیت ۱ تقریباً چنین بوده است:

$$A^{(1)} \approx \begin{pmatrix} 0.794 & 0.206 \\ 0.369 & 0.631 \end{pmatrix}.$$

این یعنی وقتی کیوبیت ۱ در $|0\rangle$ آماده شده، حدود 20.6% احتمال دارد 1 خوانده شود، و وقتی در $|1\rangle$ آماده شده، حدود 36.9% احتمال دارد 0 خوانده شود.

۳.۳.۱ ماتریس همبسته 16×16

برای ساخت ماتریس کامل، چهار مدل تک‌کیوبیتی روی کل دیتاست اعمال می‌شوند و برای هر shot یک بیت‌رشته پیش‌بینی شده $\hat{\mathbf{b}}$ به دست می‌آید. سپس برای هر حالت آماده‌سازی i و حالت اندازه‌گیری j شمارش انجام می‌شود:

$$M_{ij} = \frac{1}{N_i} \sum_{n: Y_n = \text{bits}(i)} \mathbb{I}[\text{bits_to_int}(\hat{\mathbf{b}}_n) = j]. \quad (5.1)$$

این ماتریس همان کانال کلاسیک خوانش چهارکیوبیتی است:

$$\mathbf{p}_{\text{measured}} = \mathbf{p}_{\text{prepared}} M.$$

اعتبارسنجی اصلی این است که برای هر سطر

$$\sum_{j=0}^{15} M_{ij} = 1.$$

در اجرای موجود، میانگین عناصر قطری این ماتریس حدود

$$\bar{F}_{\text{diag}} = \frac{1}{16} \sum_i M_{ii} \approx 0.385$$

بوده است. این عدد نشان می‌دهد خوانش چهارکیوبیتی دقیقاً به همان حالت آماده‌شده، به دلیل ضرب خطاهای چند کیوبیت و همبستگی‌ها، fidelity نسبتاً پایینی دارد.

۴.۳.۱ چرا ماتریس 16×16 برابر کرونکر چهار ماتریس 2×2 نیست؟

اگر خطای خوانش چهار کیوبیت کاملاً مستقل بود، ماتریس کامل از کرونکر محصول ماتریس‌های تک‌کیوبیتی به دست می‌آمد:

$$M_{\text{indep}} = A^{(4)} \otimes A^{(3)} \otimes A^{(2)} \otimes A^{(1)}. \quad (6.1)$$

اما این فقط تحت فرض استقلال معتبر است. در داده تجربی، ابرهای IQ نشان می‌دهند حالت دیگر کیوبیت‌ها می‌تواند توزیع خوانش یک کیوبیت را جابه‌جا کند. بنابراین

$$M \neq M_{\text{indep}}$$

و همین اختلاف حامل اطلاعات فیزیکی مهم درباره crosstalk، خطاهای همبسته و غیرقابل فاکتورسازی بودن خوانش است.

به بیان دیگر، ماتریس‌های 2×2 پاسخ متوسط هر کیوبیت را جداگانه خلاصه می‌کنند، اما ماتریس 16×16 پاسخ کل register را به صورت مشترک ثبت می‌کند. انتظار برابری این دو فقط در یک مدل ایده‌آل مستقل درست است، نه در سخت‌افزار واقعی.

۴.۱ مدارهای کوانتومی استفاده‌شده در بخش دوم

در بخش دوم، از دو خانواده مدار برای تولید توزیع احتمال ایده‌آل و نویزی استفاده شده است. در هر نمونه، بردار پارامتر

$$\theta = (\theta_1, \theta_2, \theta_3, \theta_4)$$

به طور تصادفی از بازه $[0, \pi]^4$ انتخاب می‌شود.


۱.۴.۱ مدار مستقل RY Independent

در این مدار روی هر کیوبیت فقط یک گیت R_y اعمال می‌شود:

$$R_y(\theta) = e^{-i\theta Y/2}. \quad (۷.۱)$$

اثر آن روی حالت اولیه $|0\rangle$ چنین است:

$$R_y(\theta)|0\rangle = \cos \frac{\theta}{2}|0\rangle + \sin \frac{\theta}{2}|1\rangle. \quad (۸.۱)$$




شکل ۲.۱: مدار مستقل شامل چهار گیت $R_y(\theta_i)$ و اندازه گیری نهایی. این مدار درهم تنیدگی ایجاد نمی کند و توزیع خروجی آن فاکتورسازی شده است.

پس احتمال اندازه‌گیری 1 برابر $\sin^2(\theta/2)$ و احتمال اندازه‌گیری 0 برابر $\cos^2(\theta/2)$ است. چون هیچ گیت دوکیوبیتی وجود ندارد، حالت کلی جدایی‌پذیر است و برای بیت‌رشته $s = s_1 s_2 s_3 s_4$:

$$P(s) = \prod_{k=1}^4 \left[\cos^2 \frac{\theta_k}{2} \right]^{1-s_k} \left[\sin^2 \frac{\theta_k}{2} \right]^{s_k}. \quad (9.1)$$

این مدار benchmark ساده‌ای فراهم می‌کند: اگر mitigation روی این مدار هم خوب کار نکند، روی مدارهای پیچیده‌تر قابل اعتماد نخواهد بود.

۲.۴.۱ مدار ZZ FeatureMap



شکل ۳.۱: مدار ZZFeatureMap چهارکیوبیتی. این مدار شامل لایه‌های Hadamard، گیت‌های فاز و بلوک‌های ZZ بین جفت کیوبیت‌هاست و توزیع احتمال غیرقابل فاکتورسازی تولید می‌کند.

مدار دوم با تابع `zz_feature_map` در Qiskit ساخته شده است. نقش گیت‌ها چنین است:

- **Hadamard**: حالت $|0\rangle$ را به $|+\rangle$ می‌برد و superposition اولیه ایجاد می‌کند؛
- **gate Phase**: اطلاعات پارامتر θ_i را به فاز حالت‌ها وارد می‌کند؛
- **بلوک‌های ZZ**: برهم‌کنش‌های دوتایی از نوع $Z_i Z_j$ ایجاد می‌کنند و فاز حالت‌ها را به صورت وابسته به جفت ویژگی‌ها تغییر می‌دهند؛
- **Measurement**: توزیع احتمال روی ۱۶ حالت پایه را تولید می‌کند.

در پیاده‌سازی Qiskit، برهم‌کنش‌های ZZ معمولاً با الگوی CNOT–P–CNOT ساخته می‌شوند. این بلوک معادل یک فاز شرطی دوتایی است و باعث می‌شود توزیع خروجی دیگر به صورت ضرب چهار توزیع تک‌کیوبیتی نوشته نشود. به همین دلیل، ZZ FeatureMap تست سخت‌تری برای مدل mitigation است: هم مدار هم نویز می‌توانند همبستگی ایجاد کنند.

۵.۱ سه مدل نویز خوانش

۱.۵.۱ نویز مصنوعی

در حالت synthetic، یک ماتریس flip ساده برای همه کیوبیت‌ها استفاده می‌شود:

$$A_{\text{syn}} = \begin{pmatrix} 1 - p_{01} & p_{01} \\ p_{10} & 1 - p_{10} \end{pmatrix}. \quad (۱۰.۱)$$

در تولید دیتاست، p_{01} و p_{10} معمولاً از بازه $[0.05, 0.15]$ انتخاب می‌شوند. در Qiskit Aer این نویز با ReadoutError و NoiseModel روی هر کیوبیت اعمال می‌شود.

۲.۵.۱ نویز تجربی تک‌کیوبیتی

در حالت experimental_single، چهار ماتریس $A^{(q)}$ که در بخش اول استخراج شده‌اند بارگذاری می‌شوند و برای هر کیوبیت به صورت مستقل به NoiseModel داده می‌شوند:

```
readout_error = ReadoutError(A_q)
noise_model.add_readout_error(readout_error, [q])
```

این روش خطای واقعی هر کیوبیت را لحاظ می‌کند، اما همچنان فرض می‌کند کانال کلی فاکتورسازی شده است.

۳.۵.۱ نویز تجربی همبسته

در حالت experimental_correlated، از ماتریس کامل M استفاده می‌شود. چون Qiskit Aer برای این کاربرد، اعمال مستقیم ماتریس همبسته 16×16 را به صورت error readout چندکیوبیتی در جریان

شبیه‌سازی استفاده نکرده است، نویز به شکل پس‌پردازش روی بردار احتمال اعمال می‌شود:

$$\mathbf{p}_{\text{noisy}} = \mathbf{p}_{\text{ideal}} M. \quad (11.1)$$

این رابطه دقیقاً با قرارداد سطری ماتریس سازگار است: هر مؤلفه ایده‌آل p_i بین خروجی‌های اندازه‌گیری j طبق سطر M_{ij} پخش می‌شود.

۶.۱ تولید دیتاست و مدل یادگیری ماشین

۱.۶.۱ خط لوله تولید دیتاست

برای هر نمونه دیتاست:

۱. بردار زاویه‌ها θ تصادفی تولید می‌شود؛
۲. مدار انتخاب‌شده ساخته می‌شود؛
۳. شبیه‌سازی بدون نویز انجام می‌شود و $\mathbf{p}_{\text{ideal}}$ به دست می‌آید؛
۴. یکی از سه نویز اعمال می‌شود و $\mathbf{p}_{\text{noisy}}$ تولید می‌شود؛
۵. ورودی و خروجی یادگیری ماشین ذخیره می‌شوند:

$$X = \mathbf{p}_{\text{noisy}}, \quad Y = \mathbf{p}_{\text{ideal}}.$$

هر بردار احتمال ۱۶ بعدی است و ترتیب مؤلفه‌ها مطابق حالت‌های 0000 تا 1111 است. دیتاست‌ها در ساختار

```
DataTrain/  
  independent/  
    synthetic/  
      experimental_single/  
        experimental_correlated/
```

```

zz_featuremap/
  synthetic/
    experimental_single/
      experimental_correlated/

```

ذخیره می‌شوند. در اجرای اصلی، اندازه‌ها برای train، validation و test به ترتیب ۴۵۰۰، ۱۵۰۰ و ۱۵۰۰ نمونه بوده است.

۲.۶.۱ مدل MLP

مدل یادگیری ماشین یک شبکه کاملاً متصل است:

$$16 \rightarrow 128 \rightarrow 256 \rightarrow 128 \rightarrow 16.$$

لایه خروجی Softmax دارد تا خروجی مدل یک بردار احتمال معتبر باشد. وظیفه مدل این است که نگاشت

$$f_{\theta} : \mathbf{p}_{\text{noisy}} \mapsto \hat{\mathbf{p}}_{\text{ideal}}$$

را یاد بگیرد. بنابراین این مدل یک ابزار readout error mitigation است، نه یک طبقه‌بند حالت. آموزش عمدتاً با Adam، نرخ یادگیری 10^{-3} ، size batch برابر ۶۴ و حدود ۵۱ epoch انجام شده است. تابع زیان اصلی KLDivLoss است، چون هدف نزدیک کردن دو توزیع احتمال است. در یکی از فازها از MSELoss نیز استفاده شده است.

۷.۱ معیار fidelity

۱.۷.۱ تعریف و تفسیر

برای دو توزیع احتمال $\mathbf{p}$ و $\mathbf{q}$ ، fidelity کلاسیک پروژه به صورت

$$F(\mathbf{p}, \mathbf{q}) = \left(\sum_{i=0}^{15} \sqrt{p_i q_i} \right)^2 \quad (12.1)$$

تعریف شده است. این کمیت مربع ضریب Bhattacharyya است. اگر دو توزیع یکسان باشند، $F = 1$ ؛ اگر روی حالت‌های کاملاً جدا وزن داشته باشند، $F = 0$.

از دید فیزیکی، fidelity میزان همپوشانی دو توزیع اندازه‌گیری را می‌سنجد. اگر نویز خوانش بخشی از احتمال را از حالت‌های درست به حالت‌های اشتباه منتقل کند، overlap بین توزیع ایده‌آل و نویزی کم می‌شود. اگر مدل mitigation موفق باشد، خروجی آن دوباره به توزیع ایده‌آل نزدیک می‌شود و fidelity افزایش می‌یابد.

۲.۷.۱ چرا fidelity معیار مناسبی است؟

accuracy فقط می‌گوید بیشینه احتمال یا برچسب نهایی درست بوده یا نه؛ اما در این پروژه خروجی یک توزیع کامل ۱۶ بعدی است. fidelity کل شکل توزیع را مقایسه می‌کند. مثلاً اگر دو بردار بیشینه یکسانی داشته باشند ولی احتمال‌های باقی‌مانده متفاوت باشند، fidelity این تفاوت را ثبت می‌کند.

در پروژه، fidelity در سه نقش استفاده شده است:

- **baseline**: $F(\mathbf{p}_{\text{ideal}}, \mathbf{p}_{\text{noisy}})$ ؛
- **ارزیابی مدل**: $F(\mathbf{p}_{\text{ideal}}, \hat{\mathbf{p}})$ ؛
- **مقایسه فازها**: میانگین fidelity روی ۱۵۰۰ نمونه test.

دو معیار کمکی دیگر نیز وجود دارد:

$$\|\mathbf{p} - \mathbf{q}\|_1 = \sum_i |p_i - q_i|, \quad (13.1)$$

$$D_{\text{KL}}(\mathbf{p} \parallel \mathbf{q}) = \sum_i p_i \log \frac{p_i}{q_i}. \quad (14.1)$$

KL برای آموزش مناسب است، اما fidelity برای گزارش نهایی خواناتر و bounded در بازه $[0, 1]$ است.

جدول ۱.۱: میانگین fidelity روی دیتاست‌های test. سطرها نوع مدار و نویز آموزش، ستون‌ها نویز آزمون هستند.

مدار	نویز آموزش	Synthetic	Exp. Single	Exp. Correlated
Independent	بدون آموزش	۹۰۷.۰	۷۶۸.۰	۷۶۳.۰
	Synthetic	۹۷۹.۰	۸۲۹.۰	۸۲۱.۰
	Exp. Single	۸۹۴.۰	۹۷۷.۰	۹۷۲.۰
	Exp. Correlated	۸۷۴.۰	۹۵۸.۰	۹۷۱.۰
ZZ FeatureMap	بدون آموزش	۹۳۸.۰	۸۵۳.۰	۸۶۱.۰
	Synthetic	۹۷۲.۰	۸۹۲.۰	۹۰۰.۰
	Exp. Single	۸۴۸.۰	۹۳۴.۰	۹۴۲.۰
	Exp. Correlated	۸۴۱.۰	۹۲۲.۰	۹۶۳.۰

۸.۱ نتایج و تحلیل

۱.۸.۱ جدول اصلی fidelity

۲.۸.۱ تحلیل ردیف بدون آموزش

ردیف «بدون آموزش» نشان می‌دهد نویز به تنهایی چقدر توزیع ایده‌آل را خراب می‌کند. برای مدار مستقل، fidelity نویز مصنوعی 0.907 است، اما برای نویزهای تجربی به حدود 0.76 افت می‌کند. این نشان می‌دهد نویز تجربی بسیار جدی‌تر از flip مصنوعی ساده است. برای مدار ZZ FeatureMap baseline بالاتر است؛ یعنی توزیع‌های تولیدشده توسط این مدار نسبت به همین نویزها در میانگین overlap بیشتری با ایده‌آل حفظ کرده‌اند. این الزاماً به معنای ساده‌تر بودن مسئله نیست؛ شکل توزیع احتمال در مدار ZZ متفاوت است.

۳.۸.۱ اهمیت هم‌خوانی نویز آموزش و آزمون

بهترین نتایج عمدتاً زمانی رخ می‌دهند که نویز آموزش و آزمون یکی باشند:

- Independent/Synthetic: از 0.907 به 0.979؛
- Independent/Experimental Single: از 0.768 به 0.977؛
- Independent/Experimental Correlated: از 0.763 به 0.971؛
- ZZ/Experimental Correlated: از 0.861 به 0.963.

این الگو نشان می‌دهد مدل MLP واقعاً نگاشت معکوس نویز را یاد گرفته است. اگر مدل فقط smooth-ing یا یک تبدیل عمومی انجام می‌داد، چنین وابستگی قوی به نوع نویز آموزش دیده نمی‌شد.

۴.۸.۱ وقتی نویز آموزش و آزمون متفاوت است

نتایج خارج از قطر جدول بسیار آموزنده‌اند. آموزش روی نویز مصنوعی و آزمون روی نویز تجربی عملکرد متوسطی دارد؛ مثلاً برای مدار مستقل fidelity روی Exp. Single برابر 0.829 است. این یعنی نویز مصنوعی برای debug مفید است، اما برای مدل‌سازی سخت‌افزار کافی نیست.

از طرف دیگر، آموزش روی نویز تجربی تک‌کیوبیتی و آزمون روی نویز همبسته در مدار مستقل fidelity 0.972 می‌دهد که بسیار خوب است. این نتیجه نشان می‌دهد بخش عمده نویز همبسته در این دیتاست هنوز از مؤلفه‌های تک‌کیوبیتی قوی تشکیل شده است. با این حال، در مدار ZZ تفاوت‌ها مهم‌تر می‌شوند و آموزش همبسته بهترین مقدار ستون Exp. Correlated یعنی 0.963 را می‌دهد.

یک نکته هشداردهنده نیز وجود دارد: برای ZZ FeatureMap، مدل آموزش‌دیده روی Exp. Single وقتی روی Synthetic تست می‌شود fidelity 0.848 دارد، در حالی که baseline بدون آموزش 0.938 بوده است. پس آموزش روی نویز نامتناسب می‌تواند از عدم آموزش بدتر باشد. این نکته برای استفاده عملی بسیار مهم است: مدل mitigation باید با نویز واقعی یا حداقل نویزی نزدیک به سخت‌افزار آموزش داده شود.

۵.۸.۱ بهبود نسبت به baseline

جدول ۲.۱: بهبود fidelity در حالت هم‌خوانی نویز آموزش و آزمون.

مدار	نویز	baseline	بهبود پس از آموزش
Independent	Synthetic	۹۰۷.۰	۰۷۲.۰+
Independent	Exp. Single	۷۶۸.۰	۲۰۹.۰+
Independent	Exp. Correlated	۷۶۳.۰	۲۰۸.۰+
ZZ FeatureMap	Synthetic	۹۳۸.۰	۰۳۴.۰+
ZZ FeatureMap	Exp. Single	۸۵۳.۰	۰۸۱.۰+
ZZ FeatureMap	Exp. Correlated	۸۶۱.۰	۱۰۲.۰+

جدول ۲.۱ نشان می‌دهد بیشترین سود یادگیری ماشین در جایی است که نویز تجربی شدیدتر بوده است. در مدار مستقل، نویز تجربی fidelity را حدود 0.76 کرده و مدل آن را تا حدود 0.97 برگردانده است. در مدار ZZ هاها baseline بالاترند، اما مدل همچنان بهبود معنادار ایجاد می‌کند.

۹.۱ نکات حساس و توصیه‌های عملی

۱. ترتیب بیت‌ها: قرارداد معادله (۲.۱) باید در همه جا ثابت بماند. هر تغییر کوچک در ordering می‌تواند کل ماتریس 16×16 را جابه‌جا کند.
۲. قرارداد سطری ماتریس: همیشه $A_{ij} = P(m = j | p = i)$ است. بنابراین اعمال نویز همبسته به صورت $p_{ideal} M$ انجام می‌شود.
۳. ماتریس 16×16 را با کرونکر اشتباه نگیریم: کرونکر فقط مدل مستقل است؛ ماتریس تجربی کامل اطلاعات crosstalk و correlation را دارد.
۴. نویز مصنوعی کافی نیست: برای ارزیابی واقعی، باید حداقل از experimental_single و بهتر از آن از experimental_correlated استفاده شود.
۵. مدل mitigation باید با شرایط آزمون سازگار باشد: mismatch بین نویز train و test می‌تواند fidelity را از baseline پایین‌تر ببرد.

۱۰.۱ جمع‌بندی نهایی

این پروژه یک مسیر کامل و قابل دفاع برای مطالعه نویز خوانش چهار کیوبیتی ساخته است. در بخش اول، داده‌های خام IQ با LDA به بیت‌های اندازه‌گیری شده تبدیل می‌شوند و از آن‌ها ماتریس‌های تخصیص تک‌کیوبیتی و ماتریس همبسته 16×16 استخراج می‌شود. شکل ابرهای IQ نشان می‌دهد خطای خوانش صرفاً یک خطای مستقل ساده نیست و crosstalk بین کیوبیت‌ها وجود دارد.

در بخش دوم، سه نوع نویز روی دو مدار کوانتومی اعمال می‌شود. مدار Independent RY یک benchmark ساده و فاکتورسازی شده است، در حالی که ZZ FeatureMap با گیت‌های فاز و برهم‌کنش‌های ZZ توزیع‌های پیچیده‌تر و همبسته‌تر تولید می‌کند. مدل MLP با ورودی p_{noisy} و هدف p_{ideal} نقش یک ابزار mitigation readout را دارد.

نتایج fidelity نشان می‌دهد یادگیری ماشین در حالت هم‌خوانی نویز آموزش و آزمون بسیار مؤثر است، به‌ویژه برای نویزهای تجربی. اما همین نتایج هشدار می‌دهند که آموزش روی نویز نامتناسب می‌تواند عملکرد را بدتر کند. بنابراین برای کاربرد سخت‌افزاری، مهم‌ترین گام، استخراج دقیق ماتریس نویز واقعی و آموزش مدل روی دیتاستی است که همان کانال نویز را بازتاب دهد.

Bibliography