

گزارش فنی پروژه نويز خوانش چهار كيوبیتی

۱.۰ هدف و تصوير کلی

هدف این گزارش، مستندسازی یک خط لوله کامل برای مدل‌سازی نويز خوانش در یک سامانه چهار كيوبیتی است. پروژه از داده‌های خام تجربی IQ شروع می‌شود، از روی آن‌ها ماتریس‌های خطای خوانش را استخراج می‌کند، سپس این نويزها را روی مدارهای کوانتومی اعمال می‌کند و در نهایت با یک مدل یادگیری ماشین تلاش می‌کند توزیع احتمال نويزی را به توزیع ایده‌آل بازگرداند.

دو فایل اصلی پروژه چنین نقشی دارند:

- `readout_matrix.ipynb`: بارگذاری داده‌های تجربی، آموزش تفکیک‌کننده IQ، استخراج ماتریس‌های 2×2 و 16×16 ؛

- `noisy_4q_zzfeaturemap.ipynb`: ساخت مدار، اعمال سه نوع نويز، تولید دیتاست، آموزش MLP و ارزیابی با `fidelity`.


در کل پروژه یک قرارداد مهم حفظ می‌شود: ماتریس نويز خوانش به صورت

$$A_{ij} = P(\text{measured} = j \mid \text{prepared} = i) \quad (1)$$

تعریف شده است. بنابراین سطرها حالت آماده‌سازی و ستون‌ها حالت اندازه‌گیری هستند و هر سطر جمع یک دارد. این همان قرارداد مورد استفاده در `Qiskit ReadoutError` است.

۲.۰ معماری کلی خط لوله پروژه

پروژه یک مسیر پیوسته از داده خام تا ارزیابی mitigation دارد. شکل ۱ این مسیر را به صورت یک سیستم واحد نشان می‌دهد؛ نه چند آزمایش جدا.



شکل ۱: معماری کلی خط لوله: از داده IQ تا استخراج ماتریس نویز، تولید توزیع ایده‌آل/نویزی، miti- gation با MLP و ارزیابی.

دو شاخه اصلی:

۱. شاخه کالیبراسیون: داده IQ → LDA → ماتریس‌های نویز؛

۲. شاخه mitigation: مدار کوانتومی $P_{ideal} \rightarrow P_{noisy}$ و $P_{ideal} \rightarrow MLP \rightarrow \hat{P}_{ideal}$.

شاخه اول «مدل نویز سخت‌افزار» را می‌سازد؛ شاخه دوم از آن برای تولید دیتاست و ارزیابی استفاده می‌کند.

۳.۰ داده‌های تجربی IQ

۱.۳.۰ ساختار فایل‌ها

داده‌های تجربی در پوشه quadrature_data_4qubits قرار دارند. برای هر یک از ۱۶ حالت پایه محاسباتی یک فایل وجود دارد؛ از 0000.txt تا 1111.txt. هر فایل چهار خط دارد؛ هر خط مربوط

به یک کیوبیت است و شامل ۱۰۰۰ نمونه مختلط از نوع

$$z = I + iQ$$

است. بنابراین برای هر حالت آماده‌سازی، ۱۰۰۰ shot و برای کل پروژه

$$16 \times 1000 = 16000$$

نمونه چهارکیوبیتی داریم. پس از بارگذاری:

$$X \in \mathbb{C}^{16000 \times 4}, \quad Y \in \{0, 1\}^{16000 \times 4}.$$

در این نمایش، $X[n, q]$ نمونه IQ کیوبیت q در shot شماره n و $Y[n, q]$ بیت آماده‌سازی همان کیوبیت است.

۲.۳.۰ برچسب‌گذاری و ترتیب بیت‌ها


برچسب‌ها از نام فایل به دست می‌آیند. در کد، تابع `bits_from_filename` نام فایل را خوانده و برای سازگاری با ترتیب داخلی پروژه، بیت‌ها را معکوس می‌کند. قرارداد اندیس‌گذاری حالت‌ها چنین است:

$$i = b_1 + 2b_2 + 4b_3 + 8b_4. \quad (۲)$$

پس b_1 کم‌ارزش‌ترین بیت است و b_4 پرازش‌ترین بیت. این قرارداد باید در همه بخش‌ها، از ساخت ماتریس نویز تا تبدیل شمارش‌های Qiskit به بردار احتمال، یکسان بماند.

۳.۳.۰ ابرهای IQ و معنای فیزیکی آن‌ها

در اندازه‌گیری dispersive، خروجی هر shot یک نقطه در صفحه IQ است. اگر کیوبیت در حالت $|0\rangle$ آماده شده باشد، نقاط باید اطراف یک ابر و اگر در $|1\rangle$ آماده شده باشد اطراف ابر دیگری قرار گیرند. هرچه این دو ابر جداتر باشند، fidelity readout بالاتر است. همپوشانی ابرها همان ناحیه‌ای است که در آن تفکیک‌کننده ممکن است 0 را 1 یا 1 را 0 تشخیص دهد.



شکل ۲: ابرهای IQ برای دو حالت چهارکیوبیتی 1010 و 0101. هر پنل مربوط به یک کیوبیت است. جدایی و همپوشانی ابرها نشان می‌دهد خطای خوانش برای هر کیوبیت چقدر است و آیا crosstalk بین کیوبیت‌ها وجود دارد یا نه.

شکل ۲ چند نکته مهم را نشان می‌دهد. نخست، جدایی ابرها برای همه کیوبیت‌ها یکسان نیست، پس ماتریس‌های تک‌کیوبیتی نباید الزاماً مشابه باشند. دوم، شکل ابرها فقط تابع بیت همان کیوبیت نیست و حالت کلی چهارکیوبیتی هم می‌تواند مرکز یا پراکندگی ابر را تغییر دهد. این رفتار نشانه‌ای از crosstalk و دلیل اصلی نیاز به ماتریس همبسته 16×16 است.

۴.۰ استخراج ماتریس‌های نویز خوانش

۱.۴.۰ مدل Linear Discriminant Analysis

در بخش اول پروژه، برای هر کیوبیت یک مدل LinearDiscriminantAnalysis یا LDA آموزش داده شده است. ورودی مدل برای کیوبیت q بردار دوبعدی

$$\mathbf{x} = (I, Q)^T$$

و برچسب آن 0 یا 1 است. داده‌ها با train_test_split و نسبت 80/20 تقسیم می‌شوند و ویژگی‌ها قبل از آموزش با StandardScaler نرمال‌سازی می‌شوند.

LDA فرض می‌کند دو کلاس 0 و 1 در صفحه IQ تقریباً توزیع گاوسی با کواریانس مشترک دارند. برای کلاس k تابع امتیاز به صورت

$$\delta_k(\mathbf{x}) = \mathbf{x}^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log \pi_k \quad (۳)$$

نوشته می‌شود. در این رابطه μ_k میانگین کلاس، Σ کواریانس مشترک و π_k prior کلاس است. مدل نمونه را به کلاسی نسبت می‌دهد که δ_k بزرگ‌تری دارد. برای دو کلاس، مرز تصمیم یک خط در صفحه

IQ است:

$$\mathbf{w}^T \mathbf{x} + w_0 = 0, \quad \mathbf{w} = \Sigma^{-1}(\mu_1 - \mu_0).$$

انتخاب LDA برای این پروژه منطقی است، چون مسئله تفکیک IQ دوبعدی است، مدل پایدار و قابل تفسیر است و هدف اصلی صرفاً بیشینه کردن accuracy نیست؛ هدف ساختن تخمینی پایدار از احتمال‌های $P(m|p)$ است. در نوت‌بوک، QDA نیز آزمایش شده است، اما LDA به عنوان گزینه ساده‌تر و پایدارتر انتخاب شده است.

۲.۴.۰ ماتریس‌های تک‌کیوبیتی 2×2

پس از آموزش مدل کیوبیت q ، خروجی model روی داده test با برچسب واقعی مقایسه می‌شود. ماتریس تخصیص تک‌کیوبیتی از ماتریس confusion نرمال‌شده ساخته می‌شود:

$$A^{(q)} = \begin{pmatrix} P(m_q = 0|p_q = 0) & P(m_q = 1|p_q = 0) \\ P(m_q = 0|p_q = 1) & P(m_q = 1|p_q = 1) \end{pmatrix}. \quad (۴)$$

در این ماتریس، عناصر قطری fidelity خوانش حالت‌های 0 و 1 هستند و عناصر غیرقطری احتمال خطای flip در خوانش را نشان می‌دهند. برای مثال، در یکی از اجراها ماتریس کیوبیت ۱ تقریباً چنین بوده است:

$$A^{(1)} \approx \begin{pmatrix} 0.794 & 0.206 \\ 0.369 & 0.631 \end{pmatrix}.$$

این یعنی وقتی کیوبیت ۱ در $|0\rangle$ آماده شده، حدود 20.6% احتمال دارد 1 خوانده شود، و وقتی در $|1\rangle$ آماده شده، حدود 36.9% احتمال دارد 0 خوانده شود.

۳.۴.۰ ماتریس همبسته 16×16

برای ساخت ماتریس کامل، چهار مدل تک‌کیوبیتی روی کل دیتاست اعمال می‌شوند و برای هر shot یک بیت‌رشته پیش‌بینی شده $\hat{\mathbf{b}}$ به دست می‌آید. سپس برای هر حالت آماده‌سازی i و حالت اندازه‌گیری j شمارش انجام می‌شود:

$$M_{ij} = \frac{1}{N_i} \sum_{n: Y_n = \text{bits}(i)} \mathbb{1}[\text{bits_to_int}(\hat{\mathbf{b}}_n) = j]. \quad (۵)$$

این ماتریس همان کانال کلاسیک خوانش چهارکیوبیتی است:

$$\mathbf{P}_{\text{measured}} = \mathbf{P}_{\text{prepared}} M.$$

اعتبارسنجی اصلی این است که برای هر سطر

$$\sum_{j=0}^{15} M_{ij} = 1.$$

در اجرای موجود، میانگین عناصر قطری این ماتریس حدود

$$\bar{F}_{\text{diag}} = \frac{1}{16} \sum_i M_{ii} \approx 0.385$$

بوده است. این عدد نشان می‌دهد خوانش چهارکیوبیتی دقیقاً به همان حالت آماده‌شده، به دلیل ضرب خطاهای چند کیوبیت و همبستگی‌ها، fidelity نسبتاً پایینی دارد.

۴.۴.۰ اعتبارسنجی ماتریس‌های نویز

استخراج ماتریس کافی نیست؛ باید مطمئن شویم خروجی یک کانال احتمال معتبر است. در غیر این صورت نمی‌توان آن را در شبیه‌سازی یا mitigation استفاده کرد.

بررسی‌های اصلی:

$$A_{ij} \geq 0 \quad \text{(غیرمنفی بودن)} \quad (۶)$$

$$\sum_j A_{ij} = 1 \quad \text{(نرمال‌سازی سطری)} \quad (۷)$$

$$\bar{A}_{ii} = \frac{1}{16} \sum_i A_{ii} \quad \text{(رفتار قطری)} \quad (۸)$$

$$M \neq A^{(1)} \otimes A^{(2)} \otimes A^{(3)} \otimes A^{(4)} \quad \text{(عدم استقلال)} \quad (۹)$$

این اعتبارسنجی تضمین می‌کند ماتریس استخراج‌شده را می‌توان مستقیماً به عنوان کانال readout در تولید $\mathbf{p}_{\text{noisy}}$ استفاده کرد. اگر قرارداد سطری Qiskit رعایت نشود یا ordering بیت‌ها جابه‌جا شود، ماتریس از نظر ریاضی stochastic به نظر می‌رسد اما فیزیکاً اشتباه خواهد بود.

جدول ۱: چک لیست اعتبارسنجی ماتریس نویز

معنی فیزیکی	شرط	بررسی
احتمال منفی معنا ندارد	$A_{ij} \geq 0$	غیرمنفی
هر حالت آماده به توزیع کامل می رود	$\sum_j A_{ij} = 1$	نرمال سازی
میانگین fidelity خوانش	$\bar{A}_{ii} \approx 0.39$	قطری
وجود correlation / crosstalk	$M \neq M_{\text{indep}}$	مقایسه

۵.۴.۰ چرا ماتریس 16×16 برابر کرونکر چهار ماتریس 2×2 نیست؟

اگر خطای خوانش چهار کیوبیت کاملاً مستقل بود، ماتریس کامل از کرونکر محصول ماتریس های تک کیوبیتی به دست می آمد:

$$M_{\text{indep}} = A^{(4)} \otimes A^{(3)} \otimes A^{(2)} \otimes A^{(1)}. \quad (10)$$

اما این فقط تحت فرض استقلال معتبر است. در داده تجربی، ابرهای IQ نشان می دهند حالت دیگر کیوبیت ها می تواند توزیع خوانش یک کیوبیت را جابه جا کند. بنابراین

$$M \neq M_{\text{indep}}$$

و همین اختلاف حامل اطلاعات فیزیکی مهم درباره crosstalk خطاهای همبسته و غیرقابل فاکتورسازی بودن خوانش است.

به بیان دیگر، ماتریس های 2×2 پاسخ متوسط هر کیوبیت را جداگانه خلاصه می کنند، اما ماتریس 16×16 پاسخ کل register را به صورت مشترک ثبت می کند. انتظار برابری این دو فقط در یک مدل ایده آل مستقل درست است، نه در سخت افزار واقعی.


۵.۰ مدارهای کوانتومی استفاده شده در بخش دوم

در بخش دوم، از دو خانواده مدار برای تولید توزیع احتمال ایده آل و نویزی استفاده شده است. در هر نمونه، بردار پارامتر

$$\theta = (\theta_1, \theta_2, \theta_3, \theta_4)$$

به طور تصادفی از بازه $[0, \pi]^4$ انتخاب می شود.

۱.۵.۰ مدار مستقل RY Independent RY



شکل ۳: مدار مستقل شامل چهار گیت $R_y(\theta_i)$ و اندازه‌گیری نهایی. این مدار درهم‌تنیدگی ایجاد نمی‌کند و توزیع خروجی آن فاکتورسازی شده است.

در این مدار روی هر کیوبیت فقط یک گیت R_y اعمال می‌شود:

$$R_y(\theta) = e^{-i\theta Y/2}. \quad (۱۱)$$

اثر آن روی حالت اولیه $|0\rangle$ چنین است:


$$R_y(\theta)|0\rangle = \cos\frac{\theta}{2}|0\rangle + \sin\frac{\theta}{2}|1\rangle. \quad (۱۲)$$

پس احتمال اندازه‌گیری ۱ برابر $\sin^2(\theta/2)$ و احتمال اندازه‌گیری ۰ برابر $\cos^2(\theta/2)$ است. چون هیچ گیت دوکیوبیتی وجود ندارد، حالت کلی جدایی‌پذیر است و برای بیت‌رشته $s = s_1 s_2 s_3 s_4$:

$$P(s) = \prod_{k=1}^4 \left[\cos^2 \frac{\theta_k}{2} \right]^{1-s_k} \left[\sin^2 \frac{\theta_k}{2} \right]^{s_k}. \quad (۱۳)$$

این مدار benchmark ساده‌ای فراهم می‌کند: اگر mitigation روی این مدار هم خوب کار نکند، روی مدارهای پیچیده‌تر قابل اعتماد نخواهد بود.

۲.۵.۰ مدار ZZ FeatureMap



شکل ۴: مدار ZZFeatureMap چهارکیوبیتی. این مدار شامل لایه‌های Hadamard، گیت‌های فاز و بلوک‌های ZZ بین جفت کیوبیت‌هاست و توزیع احتمال غیرقابل فاکتورسازی تولید می‌کند.

مدار دوم با تابع `zz_feature_map` در Qiskit ساخته شده است. نقش گیت‌ها چنین است:

- **Hadamard**: حالت $|0\rangle$ را به $|+\rangle$ می‌برد و superposition اولیه ایجاد می‌کند؛
- **gate Phase**: اطلاعات پارامتر θ_i را به فاز حالت‌ها وارد می‌کند؛
- **بلوک‌های ZZ**: برهم‌کنش‌های دوتایی از نوع $Z_i Z_j$ ایجاد می‌کنند و فاز حالت‌ها را به صورت وابسته به جفت ویژگی‌ها تغییر می‌دهند؛
- **Measurement**: توزیع احتمال روی ۱۶ حالت پایه را تولید می‌کند.

در پیاده‌سازی Qiskit، برهم‌کنش‌های ZZ معمولاً با الگوی CNOT-P-CNOT ساخته می‌شوند. این بلوک معادل یک فاز شرطی دوتایی است و باعث می‌شود توزیع خروجی دیگر به صورت ضرب چهار توزیع تک‌کیوبیتی نوشته نشود. به همین دلیل، ZZ FeatureMap تست سخت‌تری برای مدل mitigation است: هم مدار هم نویز می‌توانند همبستگی ایجاد کنند.

۶.۰ سه مدل نویز خوانش

۱.۶.۰ نویز مصنوعی

در حالت synthetic، یک ماتریس flip ساده برای همه کیوبیت‌ها استفاده می‌شود:

$$A_{\text{syn}} = \begin{pmatrix} 1 - p_{01} & p_{01} \\ p_{10} & 1 - p_{10} \end{pmatrix}. \quad (۱۴)$$

در تولید دیتاست، p_{01} و p_{10} معمولاً از بازه $[0.05, 0.15]$ انتخاب می‌شوند. در Qiskit Aer این نویز با ReadoutError و NoiseModel روی هر کیوبیت اعمال می‌شود.

۲.۶.۰ نویز تجربی تک کیوبیتی

در حالت experimental_single، چهار ماتریس $A^{(q)}$ که در بخش اول استخراج شده‌اند بارگذاری می‌شوند و برای هر کیوبیت به صورت مستقل به NoiseModel داده می‌شوند:

```
readout_error = ReadoutError(A_q)
noise_model.add_readout_error(readout_error, [q])
```

این روش خطای واقعی هر کیوبیت را لحاظ می‌کند، اما همچنان فرض می‌کند کانال کلی فاکتورسازی شده است.

۳.۶.۰ نویز تجربی همبسته

در حالت experimental_correlated، از ماتریس کامل M استفاده می‌شود. چون Qiskit Aer برای این کاربرد، اعمال مستقیم ماتریس همبسته 16×16 را به صورت error readout چندکیوبیتی در جریان شبیه‌سازی استفاده نکرده است، نویز به شکل پس‌پردازش روی بردار احتمال اعمال می‌شود:

$$\mathbf{p}_{\text{noisy}} = \mathbf{p}_{\text{ideal}} M. \quad (۱۵)$$

این رابطه دقیقاً با قرارداد سطری ماتریس سازگار است: هر مؤلفه ایده‌آل p_i بین خروجی‌های اندازه‌گیری j طبق سطر M_{ij} پخش می‌شود.

۷.۰ تولید دیتاست، استراتژی آزمایش و مدل یادگیری ماشین

۱.۷.۰ استراتژی طراحی دیتاست‌ها

ساختار پوشه‌های DataTrain فقط یک سازماندهی فایل نیست؛ پشت آن یک منطق آزمایشی مشخص قرار دارد. هدف صرفاً *interpolation* روی یک مدار و یک نویز نبود، بلکه بررسی **generalization** نسبت به تغییر مدار و تغییر کانال نویز نیز مدنظر بود.

جدول ۲: منطق طراحی دیتاست در فازهای مختلف

فاز	Train	Validation	Test
۰	—	—	Independent $\times 3$ نویز
۱	Ind. + Synthetic	Ind. + Synthetic	Ind. $\times 3$ نویز
۰ ۲	Ind. + Exp. Single	Ind. + Exp. Single	Ind. $\times 3$ نویز
۱-۲	Ind. + Exp. Corr.	Ind. + Exp. Corr.	Ind. $\times 3$ نویز
۰-۳	ZZ + Synthetic	ZZ + Synthetic	ZZ $\times 3$ نویز
۱-۳	ZZ + Exp. Single	ZZ + Exp. Single	Ind. یا ZZ $\times 3$ نویز
۲-۳	ZZ + Exp. Corr.	ZZ + Exp. Corr.	ZZ $\times 3$ نویز

سه سطح تعمیم‌پذیری:

۱. همان مدار، همان نویز (قطری جدول نتایج): بهترین عملکرد؛
۲. همان مدار، نویز متفاوت: سنجش robustness کانال نویز؛
۳. مدار متفاوت، نویز متفاوت: سخت‌ترین حالت. generalization.

۲.۷.۰ خط لوله تولید دیتاست

برای هر نمونه دیتاست:

۱. بردار زاویه‌ها θ تصادفی تولید می‌شود؛
۲. مدار انتخاب‌شده ساخته می‌شود؛
۳. شبیه‌سازی بدون نویز انجام می‌شود و p_{ideal} به دست می‌آید؛
۴. یکی از سه نویز اعمال می‌شود و p_{noisy} تولید می‌شود؛

۵. ورودی و خروجی یادگیری ماشین ذخیره می‌شوند:

$$X = \mathbf{p}_{\text{noisy}}, \quad Y = \mathbf{p}_{\text{ideal}}.$$

هر بردار احتمال ۱۶ بعدی است و ترتیب مؤلفه‌ها مطابق حالت‌های ۰۰۰۰ تا ۱۱۱۱ است. دیتاست‌ها در ساختار

```
DataTrain/  
  independent/  
    synthetic/  
    experimental_single/  
    experimental_correlated/  
  zz_featuremap/  
    synthetic/  
    experimental_single/  
    experimental_correlated/
```

ذخیره می‌شوند. در اجرای اصلی، اندازه‌ها برای validation train و test به ترتیب ۴۵۰۰، ۱۵۰۰ و ۱۵۰۰ نمونه بوده است.

۳.۷.۰ نقش مدل MLP: تقریب کانال معکوس

مدل یادگیری ماشین یک شبکه کاملاً متصل است:

$$16 \rightarrow 128 \rightarrow 256 \rightarrow 128 \rightarrow 16.$$

لایه خروجی Softmax دارد تا $\hat{p}$ یک بردار احتمال معتبر باشد.

مدل MLP چیست و چه نیست:

- نیست classifier حالت $|s\rangle$ ؛

- نیست discriminator state روی IQ؛

• است تقریب غیرخطی از $channel\ readout\ inverse$:

$$f_{\theta} \approx \mathcal{M}^{-1}, \quad \hat{\mathbf{p}}_{ideal} = f_{\theta}(\mathbf{p}_{noisy}).$$

مدل M^{-1} را به صورت صریح محاسبه نمی‌کند (ماتریس 16×16 لزوماً معکوس پذیر نیست). در عوض، یک نگاشت غیرخطی $\mathbb{R}^{16} \rightarrow \mathbb{R}^{16}$ یاد می‌گیرد که توزیع نویزی را به توزیع ایده‌آل نزدیک کند. از نظر علمی، این learned readout error mitigation است.

آموزش با Adam ($lr = 10^{-3}$)، size batch ۶۴ و حدود ۵۱ epoch انجام شده است. زیان اصلی KLDivLoss است؛ در فاز 3_2 از MSELoss نیز استفاده شده است.

۸.۰ معیار fidelity و ها baseline

۱.۸.۰ تعریف و تفسیر

برای دو توزیع احتمال p و q ، fidelity کلاسیک پروژه به صورت

$$F(\mathbf{p}, \mathbf{q}) = \left(\sum_{i=0}^{15} \sqrt{p_i q_i} \right)^2 \quad (۱۶)$$

تعریف شده است. این کمیت مربع ضریب Bhattacharyya است. اگر دو توزیع یکسان باشند، $F = 1$ ؛ اگر روی حالت‌های کاملاً جدا وزن داشته باشند، $F = 0$.

از دید فیزیکی، fidelity میزان همپوشانی دو توزیع اندازه‌گیری را می‌سنجد. اگر نویز خوانش بخشی از احتمال را از حالت‌های درست به حالت‌های اشتباه منتقل کند، overlap بین توزیع ایده‌آل و نویزی کم می‌شود. اگر مدل mitigation موفق باشد، خروجی آن دوباره به توزیع ایده‌آل نزدیک می‌شود و fidelity افزایش می‌یابد.

۲.۸.۰ چرا fidelity معیار مناسبی است؟

accuracy فقط می‌گوید بیشینه احتمال یا برچسب نهایی درست بوده یا نه؛ اما در این پروژه خروجی یک توزیع کامل ۱۶ بعدی است. fidelity کل شکل توزیع را مقایسه می‌کند. مثلاً اگر دو بردار بیشینه یکسانی

داشته باشند ولی احتمال‌های باقی‌مانده متفاوت باشند، fidelity این تفاوت را ثبت می‌کند.

در پروژه، fidelity در سه نقش استفاده شده است:

• **baseline**: $F(\mathbf{p}_{\text{ideal}}, \mathbf{p}_{\text{noisy}})$ ؛

• **ارزیابی مدل**: $F(\mathbf{p}_{\text{ideal}}, \hat{\mathbf{p}})$ ؛

• **مقایسه فازها**: میانگین fidelity روی ۱۵۰۰ نمونه. test.

دو معیار کمکی دیگر نیز وجود دارد:

$$\|\mathbf{p} - \mathbf{q}\|_1 = \sum_i |p_i - q_i|, \quad (17)$$

$$D_{\text{KL}}(\mathbf{p} \parallel \mathbf{q}) = \sum_i p_i \log \frac{p_i}{q_i}. \quad (18)$$

KL برای آموزش مناسب است، اما fidelity برای گزارش نهایی خواناتر و bounded در بازه $[0, 1]$ است.

۳.۸.۰ سه حالت مقایسه در ارزیابی

هدف پروژه «بالا بردن fidelity به هر قیمتی» نیست؛ هدف کاهش اثر نویز خوانش است. سه حالت زیر همیشه باید با هم مقایسه شوند:

$$F_{\text{raw}} = F(\mathbf{p}_{\text{ideal}}, \mathbf{p}_{\text{noisy}}) \quad \text{حالت ۱ — بدون mitigation} \quad (19)$$

$$F_{\text{MLP}} = F(\mathbf{p}_{\text{ideal}}, \hat{\mathbf{p}}) \quad \text{حالت ۲ — پس از MLP} \quad (20)$$

$$\Delta F = F_{\text{MLP}} - F_{\text{raw}} \quad \text{حالت ۳ — بهبود} \quad (21)$$

اگر F_{raw} از ابتدا نزدیک ۱ باشد (مثلاً 0.972 در ZZFeatureMap اولیه)، ΔF کوچک لزوماً به معنای مدل ضعیف نیست؛ ممکن است نویز از ابتدا کم اثر بوده باشد. بنابراین همیشه باید baseline خام و بهبود نسبی را با هم گزارش کرد.

شکل ۵ نشان می‌دهد چرا fidelity معیار مناسب‌تری از accuracy است: حتی اگر argmax یکسان بماند، توزیع کامل تغییر کرده و mitigation باید این تغییر را جبران کند.



شکل ۵: نمایش مفهومی بازسازی توزیع: ایده‌آل (چپ)، نویزی (وسط)، خروجی MLP (راست). هدف mitigation بازگرداندن شکل توزیع است، نه فقط بیشینه احتمال.

۹.۰ چالش‌ها، اصلاحات و نتایج

۱.۹.۰ چالش‌های پروژه و راه‌حل‌ها

پروژه فقط اجرای کد نبود؛ چند مشکل فنی در مسیر حل شد:

جدول ۳: چالش‌های اصلی و اصلاحات انجام‌شده

چالش	مشکل	راه‌حل
ترتیب بیت‌ها	جاب‌جایی سطر/ستون M	یکسان‌سازی bits_to_int در همه بخش‌ها
قرارداد Qiskit	transpose اشتباه ماتریس	$A_{ij} = P(m = j p = i)$ اعمال pM
ماتریس 16×16 ZZFeatureMap یکنواخت	Aer کانال همبسته کامل ندارد $F_{\text{raw}} \approx 0.972$ ، نویز کم‌اثر	apply_correlated_readout_noise افزایش reps به ۲
نویز train/test	عملکرد بدتر از baseline	آموزش روی نویز متناسب با سخت‌افزار

۲.۹.۰ بررسی چالش یکنواختی ZZFeatureMap

در فرآیند تولید داده برای ارزیابی عملکرد مدل یادگیری، یکی از چالش‌های مهم مربوط به استفاده از مدار ZZFeatureMap مشاهده شد. در مراحل اولیه، داده‌های مربوط به این مدار با پارامترهای تصادفی و تعداد لایه کم ($\text{reps}=1$) تولید شدند. بررسی اولیه نشان داد که شباهت بین توزیع ایده‌آل و توزیع نویزی حتی پیش از اعمال مدل یادگیری بسیار زیاد است. به عنوان نمونه، مقدار فیدیلیتی خام بین داده‌های ایده‌آل و نویزی به صورت زیر مشاهده شد:

$$F_{\text{raw}} \approx 0.972 \quad (22)$$

این مقدار نشان می‌دهد که ورودی مدل (توزیع نویزی) و خروجی هدف (توزیع ایده‌آل) از ابتدا اختلاف بسیار کمی دارند. بنابراین اگر پس از آموزش مدل، مقدار فیدیلیتی بالایی مانند $F \approx 0.996$ مشاهده شود،

این نتیجه الزاماً نشان‌دهنده توانایی بالای مدل در یادگیری تصحیح نویز نیست، زیرا بخشی از این عملکرد ناشی از شباهت اولیه داده‌ها است.

بررسی توزیع‌های تولید شده نشان داد که دلیل اصلی این رفتار، ماهیت خروجی مدار ZZFeatureMap با تنظیمات اولیه بود. این مدار در حالت $\text{reps} = 1$ برای بسیاری از انتخاب‌های تصادفی پارامترها، توزیع احتمال حالت‌های اندازه‌گیری شده‌ای نزدیک به توزیع یکنواخت ایجاد می‌کند. در چنین شرایطی، اثر نویز خوانش روی توزیع احتمال کاهش پیدا می‌کند، زیرا تغییرات ایجاد شده توسط نویز در مقایسه با توزیع تقریباً یکنواخت بسیار کوچک است.

به بیان دیگر، مسئله اصلی در این مرحله، عدم صحت مدل نویز یا فرآیند اعمال ماتریس نویز نبود؛ بلکه داده‌های تولید شده از مدار، ساختار کافی برای آشکار کردن اثر نویز را نداشتند. در نتیجه مدل یادگیری ماشین عملاً با مسئله‌ای مواجه نبود که نیاز به اصلاح جدی داشته باشد.

برای رفع این مشکل، ساختار مدار تغییر داده شد و با افزایش عمق مدار از طریق افزایش تعداد لایه‌ها ($\text{reps} = 2$) تنوع بیشتری در توزیع‌های خروجی ایجاد شد. هدف از این تغییر، ایجاد یک تعادل مناسب بین دو عامل بود:

- وجود ساختار کافی در توزیع احتمال خروجی مدار، به طوری که مدل بتواند الگوهای کوانتومی را یاد بگیرد؛

- ایجاد اختلاف قابل مشاهده بین توزیع ایده‌آل و نویزی، به طوری که اثر نویز خوانش در داده‌ها باقی بماند.

پس از اصلاح مدار، مقدار خلوص توزیع‌های تولید شده افزایش یافت و در عین حال توزیع‌ها از حالت تقریباً یکنواخت خارج شدند. این تغییر باعث شد داده‌های تولید شده برای آموزش و ارزیابی مدل، چالش واقعی‌تری ایجاد کنند و عملکرد مدل در شرایط مختلف نویز قابل تفسیرتر باشد.

لازم به ذکر است که هدف در این پروژه، بیشینه کردن یا کمینه کردن مستقیم معیارهایی مانند Purity یا Fidelity نیست؛ بلکه هدف اصلی ایجاد دیتاست‌هایی است که در آن‌ها:

۱. مدارهای کوانتومی دارای ساختار قابل یادگیری باشند؛
۲. نویز خوانش بتواند تغییر قابل اندازه‌گیری در توزیع احتمال ایجاد کند؛
۳. مدل یادگیری مجبور به استخراج نداشت بین توزیع نویزی و توزیع ایده‌آل باشد.

بنابراین اصلاح پارامترهای مدار ZZFeatureMap به عنوان یک مرحله ضروری در آماده‌سازی داده انجام شد تا ارزیابی مدل در مراحل بعدی پروژه، بازتاب واقعی‌تری از توانایی مدل در کاهش اثر نویز کوانتومی داشته باشد.

۳.۹.۰ جدول اصلی fidelity

جدول ۴: میانگین fidelity روی دیتاست‌های test. سطرها نوع مدار و نویز آموزش، ستون‌ها نویز آزمون هستند.

Correlated Exp.	Single Exp.	Synthetic	TrainingNoise	Circuit
۷۶۳.۰	۷۶۸.۰	۹۰۷.۰	NoTraining	Independent
۸۲۱.۰	۸۲۹.۰	۹۷۹.۰	Synthetic	
۹۷۲.۰	۹۷۷.۰	۸۹۴.۰	Single Exp.	
۹۷۱.۰	۹۵۸.۰	۸۷۴.۰	Correlated Exp.	
۸۶۱.۰	۸۵۳.۰	۹۳۸.۰	NoTraining	FeatureMap ZZ
۹۰۰.۰	۸۹۲.۰	۹۷۲.۰	Synthetic	
۹۴۲.۰	۹۳۴.۰	۸۴۸.۰	Single Exp.	
۹۶۳.۰	۹۲۲.۰	۸۴۱.۰	Correlated Exp.	

۴.۹.۰ تحلیل ردیف بدون آموزش

ردیف «بدون آموزش» نشان می‌دهد نویز به تنهایی چقدر توزیع ایده‌آل را خراب می‌کند. برای مدار مستقل، fidelity نویز مصنوعی 0.907 است، اما برای نویزهای تجربی به حدود 0.76 افت می‌کند. این نشان می‌دهد نویز تجربی بسیار جدی‌تر از flip مصنوعی ساده است. برای مدار ZZ FeatureMap baseline بالاتر است؛ یعنی توزیع‌های تولیدشده توسط این مدار نسبت به همین نویزها در میانگین overlap بیشتری با ایده‌آل حفظ کرده‌اند. این الزاماً به معنای ساده‌تر بودن مسئله نیست؛ شکل توزیع احتمال در مدار ZZ متفاوت است.

۵.۹.۰ اهمیت هم‌خوانی نویز آموزش و آزمون

بهترین نتایج عمدتاً زمانی رخ می‌دهند که نویز آموزش و آزمون یکی باشند:

● Independent/Synthetic: از 0.907 به 0.979؛

● Independent/Experimental Single: از 0.768 به 0.977؛

● Independent/Experimental Correlated: از 0.763 به 0.971؛

● ZZ/Experimental Correlated: از 0.861 به 0.963.

این الگو نشان می‌دهد مدل MLP واقعاً نگاشت معکوس نویز را یاد گرفته است. اگر مدل فقط smooth-ing یا یک تبدیل عمومی انجام می‌داد، چنین وابستگی قوی به نوع نویز آموزش دیده نمی‌شد.

۶.۹.۰ وقتی نویز آموزش و آزمون متفاوت است

نتایج خارج از قطر جدول بسیار آموزنده‌اند. آموزش روی نویز مصنوعی و آزمون روی نویز تجربی عملکرد متوسطی دارد؛ مثلاً برای مدار مستقل fidelity روی Exp. Single برابر 0.829 است. این یعنی نویز مصنوعی برای debug مفید است، اما برای مدل‌سازی سخت‌افزار کافی نیست.

از طرف دیگر، آموزش روی نویز تجربی تک‌کیوبیتی و آزمون روی نویز همبسته در مدار مستقل fidelity 0.972 می‌دهد که بسیار خوب است. این نتیجه نشان می‌دهد بخش عمده نویز همبسته در این دیتاست هنوز از مؤلفه‌های تک‌کیوبیتی قوی تشکیل شده است. با این حال، در مدار ZZ تفاوت‌ها مهم‌تر می‌شوند و آموزش همبسته بهترین مقدار ستون Exp. Correlated یعنی 0.963 را می‌دهد.

یک نکته هشداردهنده نیز وجود دارد: برای ZZ FeatureMap، مدل آموزش دیده روی Exp. Single وقتی روی Synthetic تست می‌شود fidelity 0.848 دارد، در حالی که baseline بدون آموزش 0.938 بوده است. پس آموزش روی نویز نامتناسب می‌تواند از عدم آموزش بدتر باشد. این نکته برای استفاده عملی بسیار مهم است: مدل mitigation باید با نویز واقعی یا حداقل نویزی نزدیک به سخت‌افزار آموزش داده شود.

۷.۹.۰ بهبود نسبت به baseline

جدول ۵: بهبود fidelity در حالت هم‌خوانی نویز آموزش و آزمون.

مدار	نویز	baseline	بهبود پس از آموزش
Independent	Synthetic	۹۰۷.۰	۰۷۲.۰+
Independent	Exp. Single	۷۶۸.۰	۲۰۹.۰+
Independent	Exp. Correlated	۷۶۳.۰	۲۰۸.۰+
ZZ FeatureMap	Synthetic	۹۳۸.۰	۰۳۴.۰+
ZZ FeatureMap	Exp. Single	۸۵۳.۰	۰۸۱.۰+
ZZ FeatureMap	Exp. Correlated	۸۶۱.۰	۱۰۲.۰+

جدول ۵ نشان می‌دهد بیشترین سود یادگیری ماشین در جایی است که نویز تجربی شدیدتر بوده است. در مدار مستقل، نویز تجربی fidelity را حدود 0.76 کرده و مدل آن را تا حدود 0.97 برگردانده است. در مدار ZZ ها baseline بالاترند، اما مدل همچنان بهبود معنادار ایجاد می‌کند.

۱۰.۰ محدودیت‌های فعلی پروژه

۱. مقیاس: فقط ۴ کیوبیت بررسی شده؛ برای $n > 4$ اندازه ماتریس $2^n \times 2^n$ به سرعت رشد می‌کند.
 ۲. وابستگی به کالیبراسیون: ماتریس‌های نویز snapshot فعلی سخت‌افزار هستند و drift زمانی لحاظ نشده.
 ۳. **generalization محدود:** مدل وقتی train/test از نظر نویز یا مدار mismatch دارند، افت شدید نشان می‌دهد.
 ۴. تقریب غیرخطی: MLP معکوس دقیق M نیست؛ distribution outside ممکن است ضعیف عمل کند.
 ۵. نویز فقط: **readout** error gate و decoherence در شبیه‌سازی لحاظ نشده‌اند.
- بیان صریح این محدودیت‌ها اعتبار گزارش را بالا می‌برد و مسیر ادامه کار را روشن می‌کند.

۱۱.۰ نکات حساس و توصیه‌های عملی

۱. ترتیب بیت‌ها: قرارداد معادله (۲) باید در همه جا ثابت بماند. هر تغییر کوچک در ordering می‌تواند کل ماتریس 16×16 را جابه‌جا کند.
۲. قرارداد سطری ماتریس: همیشه $A_{ij} = P(m = j | p = i)$ است. بنابراین اعمال نویز همبسته به صورت $p_{ideal} M$ انجام می‌شود.
۳. ماتریس 16×16 را با کرونکر اشتباه نگیریم: کرونکر فقط مدل مستقل است؛ ماتریس تجربی کامل اطلاعات crosstalk و correlation را دارد.
۴. نویز مصنوعی کافی نیست: برای ارزیابی واقعی، باید حداقل از experimental_single و بهتر از experimental_correlated استفاده شود.

۵. مدل **mitigation** باید با شرایط آزمون سازگار باشد: mismatch بین نویز train و test می تواند fidelity را از baseline پایین تر ببرد.

۱۲.۰ جمع بندی نهایی

این پروژه یک مسیر کامل و قابل دفاع برای مطالعه نویز خوانش چهار کیوبیتی ساخته است (شکل ۱). در بخش اول، داده های خام IQ با LDA به بیت های اندازه گیری شده تبدیل می شوند و پس از اعتبارسنجی، ماتریس های تخصیص تک کیوبیتی و ماتریس همبسته 16×16 استخراج می شود.

در بخش دوم، سه نوع نویز روی دو مدار کوانتومی اعمال می شود. استراتژی دیتاست طوری طراحی شده که generalization نسبت به مدار و کانال نویز نیز سنجیده شود. مدل MLP نقش تقریب کانال معکوس readout را دارد و با KL fidelity و L1 ارزیابی می شود.

نتایج نشان می دهد mitigation در حالت هم خوانی train/test بسیار مؤثر است، به ویژه برای نویز تجربی. اما mismatch train/test می تواند عملکرد را از baseline پایین تر ببرد. برای کاربرد سخت افزاری، استفاده از ماتریس همبسته واقعی و طراحی دیتاست متناسب با شرایط آزمون ضروری است.