




دانشگاه صنعتی شریف
مرکز مهندسی کوانتوم و فناوری‌های فوتونیک
گروه الگوریتم و نرم‌افزار کوانتومی

گزارش فنی پروژه مدل‌سازی نویز خوانش کوانتومی و تولید دیتاست برای یادگیری ماشین سیستم چهار کیوبیتی

استخراج ماتریس‌های نویز از داده‌های تجربی IQ
و اعمال نویز بر مدارهای کوانتومی

بہمن ۱۴۰۴

فهرست مطالب

۱	گزارش جامع پروژه مدل سازی نويز خوانش و توليد ديتاست	۱
۱.۱	مقدمه و هدف پروژه	۱
۲.۱	بخش اول: داده های تجربی و استخراج ماتریس نويز	۲
۱.۲.۱	ساختار داده های ورودی	۲
۲.۲.۱	برچسب گذاری از نام فایل	۲
۳.۲.۱	بصری سازی ابر IQ	۳
۴.۲.۱	تحلیل خطی تمایز (Linear Discriminant Analysis)	۴
۵.۲.۱	ساخت ماتریس همبسته 16×16	۵
۶.۲.۱	مقایسه ماتریس واقعی با مدل کرونکر مستقل	۶
۷.۲.۱	روش دوم (اختیاری): MLP مشترک	۷
۸.۲.۱	خلاصه خروجی های بخش اول	۷
۳.۱	بخش دوم: شبیه سازی مدار، اعمال نويز و توليد ديتاست	۷
۱.۳.۱	دو خانواده مدار کوانتومی	۷
۲.۳.۱	سه مدل نويز خوانش	۱۰
۳.۳.۱	شبیه سازی و تبدیل شمارش به احتمال	۱۱
۴.۳.۱	مدل یادگیری ماشین (MLP_4Q)	۱۲
۵.۳.۱	معیار fidelity: مبانی فیزیکی و کاربرد در پروژه	۱۳
۶.۳.۱	طراح آزمایش: فازهای آموزش و ارزیابی	۱۴

۴.۱	مرجع API های Qiskit برای خطای خوانش	۱۴
۵.۱	جدول مقایسه نتایج و تحلیل	۱۴
۱.۵.۱	تحلیل نظام‌وار نتایج	۱۵
۶.۱	قراردادهای حیاتی پروژه	۱۷
۷.۱	جمع‌بندی	۱۸

۱۹	مراجع
----	-------

فصل ۱

گزارش جامع پروژه مدل سازی نویز خوانش و تولید دیتاست

۱.۱ مقدمه و هدف پروژه

این پروژه بر مدل سازی نویز خوانش (readout noise) در یک پردازنده کوانتومی چهار کیوبیتی تمرکز دارد. داده های تجربی شامل نمونه های مختلط IQ (In-phase و Quadrature) برای هر یک از ۱۶ حالت پایه محاسباتی $|s\rangle$ با $s \in \{0, 1\}^4$ هستند. هدف کلی پروژه دو بخش دارد:

۱. استخراج ماتریس های نویز از داده های تجربی: ماتریس های تخصیص تک کیوبیتی 2×2 و ماتریس همبسته 16×16 .

۲. تولید دیتاست و ارزیابی مدل یادگیری ماشین برای نگاشت توزیع احتمال اندازه گیری نویزی به ایده آل، تحت سه مدل نویز و دو خانواده مدار کوانتومی.

فایل های اصلی پروژه عبارت اند از:

- readout_matrix.ipynb — بارگذاری داده، آموزش طبقه بند، استخراج ماتریس ها؛
- noisy_4q_zzfeaturemap.ipynb — شبیه سازی مدار، اعمال نویز، تولید دیتاست، آموزش MLP و مقایسه نتایج.

۲.۱ بخش اول: داده‌های تجربی و استخراج ماتریس نویز

۱.۲.۱ ساختار داده‌های ورودی

داده‌های تجربی در پوشه quadrature_data_4qubits/ قرار دارند. برای هر حالت آماده‌سازی $s = s_1 s_2 s_3 s_4$ یک فایل txt با همان نام وجود دارد (مثلاً 0101.txt). هر فایل شامل:

- ۴ خط، هر خط مربوط به یک کیوبیت (q_1 تا q_4):

- ۱۰۰۰ نمونه مختلط $z = I + iQ$ در هر خط.

بنابراین برای هر حالت، $4 \times 1000 = 4000$ نمونه IQ داریم و در مجموع:

$$N_{\text{total}} = 16 \times 1000 = 16000 \text{ نمونه.}$$

تابع parse_complex_string رشته‌های متنی را به np.complex128 تبدیل می‌کند. تابع load_single_file آرایه‌ای به شکل (4, 1000) برمی‌گرداند که سپس به (1000, 4) transpose می‌شود.

۲.۲.۱ برچسب‌گذاری از نام فایل

برچسب هر نمونه از نام فایل استخراج می‌شود، نه از محتوای IQ. تابع bits_from_filename نام پایه فایل را معکوس می‌کند:

$$0101.\text{txt} \Rightarrow \mathbf{b} = (b_1, b_2, b_3, b_4) = (1, 0, 1, 0).$$

قرارداد اندیس‌گذاری حالت‌های 16 تایی در کل پروژه:

$$i = b_1 + 2b_2 + 4b_3 + 8b_4, \quad (1.1)$$

و تبدیل معکوس:

$$b_k = (i \gg (k-1)) \bmod 2, \quad k = 1, 2, 3, 4. \quad (2.1)$$

پس از بارگذاری همه فایل‌ها:


$$\mathbf{X} \in \mathbb{C}^{16000 \times 4}, \quad \mathbf{y} \in \{0, 1\}^{16000 \times 4},$$

که $\mathbf{X}[n, q]$ مقدار IQ کیوبیت q در شات n و $\mathbf{y}[n, q]$ برچسب آماده‌سازی آن کیوبیت است.

۳.۲.۱ بصری‌سازی ابر IQ

تابع `plot_qubit_iq_clouds` برای هر کیوبیت، نقاط $(\text{Re } z, \text{Im } z)$ را برای برچسب‌های 0 و 1 رسم می‌کند. این نمودار کیفیت جداسازی حالت‌های $|0\rangle$ و $|1\rangle$ و میزان همپوشانی (منبع خطای خوانش) را نشان می‌دهد.

تابع `plot_fourqubit_state_overlay` ابرهای دو حالت چهار کیوبیتی را روی هم می‌اندازد. در شکل ۱.۱ حالت‌های 0101 و 1010 مقایسه شده‌اند. این دو حالت برای هر کیوبیت مقدار بیت متفاوت دارند؛ بنابراین برای هر کیوبیت باید دو ابر مجزا (آبی و قرمز) ببینیم.



شکل ۱.۱: برهم‌نهی ابر IQ برای حالت‌های آماده 0101 (آبی) و 1010 (قرمز) روی چهار کیوبیت. محور افقی I و محور عمودی Q . همپوشانی ابرها مستقیماً به احتمال خطای تخصیص $A_{10}^{(q)}$ و $A_{01}^{(q)}$ مربوط است. جابه‌جایی مرکز ابرها نسبت به حالت مورد انتظار، اثر crosstalk از کیوبیت‌های دیگر را نشان می‌دهد.

تفسیر فیزیکی: پس از آماده‌سازی $|s\rangle$ و اندازه‌گیری، dispersive، سیگنال demodu- microwave باید در صفحه IQ یک نقطه تصادفی است. خوشه‌ی $|0\rangle$ و $|1\rangle$ باید separable باشند تا discriminator بتواند با خطای کم تصمیم بگیرد. در شکل ۱.۱:

- کیوبیت ۱: دو ابر با همپوشانی قابل توجه — منطبق با fidelity پایین‌تر ($\sim 71\%$)؛ (accuracy)
- کیوبیت ۲: ابرهای 0101 و 1010 تقریباً روی هم — چون در هر دو حالت $q_2 = 1$ است؛ این subplot تفاوت بین حالت‌ها را برای این کیوبیت نشان نمی‌دهد، بلکه پراکندگی shot-to-shot را نشان می‌دهد؛
- کیوبیت ۳ و ۴: جداسازی بهتر، اما هنوز tail همپوشان وجود دارد.

۴.۲.۱ تحلیل خطی تمایز (Linear Discriminant Analysis)

در `readout_matrix.ipynb` از `LinearDiscriminantAnalysis (LDA)` در `scikit-learn` برای تخصیص هر نمونه IQ به بیت 0 یا 1 استفاده شده است. در کد، QDA نیز برای مقایسه آزمایش شده، اما LDA به دلیل پایداری و سادگی به عنوان روش اصلی انتخاب شده است.

ایده و فرمول

LDA فرض می‌کند هر کلاس (0 یا 1) در فضای (I, Q) توزیع گاوسی دارد با میانگین μ_0, μ_1 و واریانس مشترک Σ . مرز تصمیم خطی است:

$$\delta_k(\mathbf{x}) = \mathbf{x}^\top \Sigma^{-1} \boldsymbol{\mu}_k - \frac{1}{2} \boldsymbol{\mu}_k^\top \Sigma^{-1} \boldsymbol{\mu}_k + \log \pi_k,$$

که $\mathbf{x} = (I, Q)^\top$ ، π_k نسبت کلاس در `train` و $k \in \{0, 1\}$. نمونه به کلاسی تخصیص می‌یابد که δ_k بیشینه باشد.

برای دو کلاس، مرز تصمیم خطی:

$$\mathbf{w}^\top \mathbf{x} + w_0 = 0, \quad \mathbf{w} = \Sigma^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0).$$

این خط در صفحه IQ همان مرز بهینه خطی بین دو ابر است — مناسب وقتی ابرها تقریباً بیضوی و هم‌واریانس باشند.

چرا LDA برای IQ readout مناسب است؟

- فضای ویژگی فقط ۲ بعد (I, Q) است؛ LDA سریع و قابل تفسیر است؛
- با `StandardScaler` قبل از LDA، مقیاس دو محور یکسان می‌شود؛
- هدف ساخت ماتریس تخصیص است، نه حداکثر `LDA accuracy`؛ یک `discriminator` خطی پایدار برای تخمین $P(m|p)$ می‌دهد؛
- در مقایسه با QDA، ماتریس 16×16 نهایی تفاوت کمی دارد (در کد: $\|M_{\text{LDA}} - M_{\text{QDA}}\|$ کوچک)؛ LDA پایدارتر است.

از پیش‌بینی LDA تا ماتریس 2×2

پس از train/test split (80/20, stratified)، مدل روی train آموزش و روی test ارزیابی می‌شود. ماتریس تخصیص از confusion_matrix با normalize="true":

$$A_{ij}^{(q)} = P(m_q = j \mid p_q = i), \quad i, j \in \{0, 1\}, \quad (3.1)$$

که p_q حالت آماده و m_q حالت اندازه‌گیری شده کیوبیت q است. این قرارداد با Qiskit سازگار است: سطر = آماده، ستون = اندازه‌گیری و هر سطر جمع 1 دارد.

ماتریس‌های $A^{(1)}, \dots, A^{(4)}$ در noise_matrix_results/assignment_matrix_q*.txt ذخیره می‌شوند.

مثال ۱.۱. برای کیوبیت ۱، دقت آزمون حدود 71% و ماتریس تقریبی:

$$A^{(1)} \approx \begin{pmatrix} 0.794 & 0.206 \\ 0.369 & 0.631 \end{pmatrix}.$$

عنصر $A_{00}^{(1)} = P(m = 0 \mid p = 0) \approx 0.79$ fidelity خوانش برای حالت $|0\rangle$ است؛ $A_{01}^{(1)}$ احتمال flip از 0 به 1.

۵.۲.۱ ساخت ماتریس همبسته 16×16

پس از آموزش چهار طبقه‌بند مستقل، پیش‌بینی روی کل داده (16000 نمونه) انجام می‌شود و بردار $\hat{\mathbf{b}}_n \in \{0, 1\}^4$ به دست می‌آید. ماتریس نویز کامل:

$$M_{ij} = P(\text{measured} = j \mid \text{prepared} = i), \quad (4.1)$$

که با شمارش فرکانس‌ها محاسبه می‌شود:

$$M_{ij} = \frac{1}{N_i} \sum_{n: \mathbf{y}_n = \text{int_to_bits}(i)} \mathbb{1}[\text{bits_to_int}(\hat{\mathbf{b}}_n) = j],$$

و N_i تعداد نمونه‌های با حالت آماده i است.

نکته مهم: M با کرونکر محصول $A^{(1)} \otimes \dots \otimes A^{(4)}$ برابر نیست، مگر آنکه خطاهای خوانش کاملاً

مستقل باشند. اختلاف $M - A_{\text{indep}}$ نشان‌دهنده همبستگی خوانش، crosstalk و خطاهای غیرقابل فاکتورسازی است. در کد:

$$A_{\text{indep}} = A^{(4)} \otimes A^{(3)} \otimes A^{(2)} \otimes A^{(1)}.$$

اعتبارسنجی: $\sum_j M_{ij} = 1$ برای هر i ؛ fidelity قطری میانگین:

$$\bar{F} = \frac{1}{16} \sum_{i=0}^{15} M_{ii} \approx 0.385.$$

۶.۲.۱ مقایسه ماتریس واقعی با مدل کرونکر مستقل

اگر خطاهای خوانش کاملاً مستقل بین کیوبیت‌ها بودند، ماتریس 16×16 از کرونکر محصول به دست می‌آمد:

$$A_{\text{indep}} = A^{(1)} \otimes A^{(2)} \otimes A^{(3)} \otimes A^{(4)}. \quad (5.1)$$

برای دو کیوبیت، عنصر $(i_1 i_2, j_1 j_2)$ برابر است با:

$$(A^{(1)} \otimes A^{(2)})_{(i_1 i_2), (j_1 j_2)} = A_{i_1 j_1}^{(1)} \cdot A_{i_2 j_2}^{(2)}.$$

در عمل $M \neq A_{\text{indep}}$ زیرا:

Cross آماده‌سازی یک کیوبیت، ابر IQ کیوبیت دیگر را جابه‌جا می‌کند (مشاهده در plot_fourqubit_state_overlay)؛

- همبستگی اندازه‌گیری: خطای خوانش چند کیوبیت همزمان فاکتورسازی‌پذیر نیست؛
- طبقه‌بند مستقل: هر کیوبیت جدا آموزش دیده؛ پیش‌بینی مشترک لزوماً کانال فیزیکی واقعی را بازتولید نمی‌کند.

تابع compare_noise_models اختلاف $\Delta = M - A_{\text{indep}}$ را با نُرم فروبنیوس، بیشینه و میانگین قدر مطلق گزارش می‌کند. این مقایسه عمدی است: M و ماتریس‌های 2×2 با روش‌های متفاوت ساخته شده‌اند و برابری کرونکر انتظار نمی‌رود؛ بلکه انحراف از آن معیار قدرت همبستگی است.

۷.۲.۱ روش دوم (اختیاری): MLP مشترک

انتهای readout_matrix.ipynb روش Joint MLP تعریف شده است. در خط لوله اصلی (noisy_4q_zzfeaturemap) از ماتریس‌های استخراج‌شده با LDA استفاده شده است.

۸.۲.۱ خلاصه خروجی‌های بخش اول

جدول ۱.۱: خروجی‌های استخراج نویز (readout_matrix.ipynb)

فایل	توضیح
assignment_matrix_q1..q4.txt	ماتریس 2×2 هر کیوبیت
noise_matrix_16x16.txt	ماتریس همبسته 16×16
noise_matrix_heatmap.png	نقشه حرارتی (اختیاری)

۳.۱ بخش دوم: شبیه‌سازی مدار، اعمال نویز و تولید دیتاست

۱.۳.۱ دو خانواده مدار کوانتومی

در این پروژه دو مدار برای تولید توزیع احتمال 16 حالتی استفاده شده‌اند. هر مدار با بردار پارامتر $\theta = (\theta_1, \dots, \theta_4)$ از بازه $[0, \pi]$ نمونه‌گیری می‌شود و پس از اجرا، بردار $\mathbf{p}_{\text{ideal}} \in \mathbb{R}^{16}$ به‌دست می‌آید.


مدار مستقل Independent RY

گیت $R_y(\theta)$: چرخش حول محور Y روی کره Bloch:

$$R_y(\theta) = e^{-i\theta Y/2}, \quad R_y(\theta)|0\rangle = \cos \frac{\theta}{2}|0\rangle + \sin \frac{\theta}{2}|1\rangle.$$

اثر بر خروجی: هر کیوبیت مستقل در superposition دودویی قرار می‌گیرد. چون درهم‌تنیدگی نیست، state کلی جدایی‌پذیر است:

$$|\psi\rangle = \bigotimes_{k=1}^4 \left(\cos \frac{\theta_k}{2}|0\rangle + \sin \frac{\theta_k}{2}|1\rangle \right).$$




شکل ۲.۱: مدار Independent RY برای چهار کیوبیت. هر خط عمودی یک R_Y با زاویه θ_i و سپس measure دارد. هیچ گیت درهم‌کننده‌ای وجود ندارد.

توزیع احتمال: احتمال هر bitstring $s = s_1 s_2 s_3 s_4$ فاکتورسازی می‌شود:

$$P(s) = \prod_{k=1}^4 \left[\cos^2 \frac{\theta_k}{2} \right]^{1-s_k} \left[\sin^2 \frac{\theta_k}{2} \right]^{s_k}.$$

با تغییر θ_k ، weight حالت‌هایی که $s_k = 1$ دارند به صورت $\sin^2(\theta_k/2)$ تغییر می‌کند. این مدار ساده‌ترین benchmark برای mitigation است: ساختار احتمال قابل فهم و بدون correlation کوانتومی.

مدار ZZ FeatureMap



شکل ۳.۱: مدار ZZ FeatureMap چهار کیوبیتی (reps=1, entanglement="full"). شامل Hadamard، $P(\theta)$ و بلوک‌های ZZ (CNOT-P-CNOT) بین جفت کیوبیت‌ها.

این مدار از `qiskit.circuit.library.zz_feature_map` ساخته می‌شود. ساختار برای $n = 4$ و `reps=1`:

۱. Hadamard روی همه: $|0\rangle^{\otimes 4} \rightarrow |+\rangle^{\otimes 4}$ superposition متقارن؛

۲. $P(\theta_i)$ روی هر کیوبیت: فاز $e^{-i\theta_i/2}$ encoding تک کیوبیتی پارامتر θ_i ؛

۳. بلوک ZZ: برای هر جفت (i, j) ؛

$$\exp\left(-i\phi_{ij} Z_i \otimes Z_j\right)$$

با $\phi_{ij} = 2(\pi - x_i)(\pi - x_j)$ (در `zz_feature_map` استاندارد Qiskit، $x_i = \theta_i$). این گیت correlation بین بیت‌های i و j ایجاد می‌کند؛

۴. تکرار (reps): با reps=2 لایه encoding عمیق تر می شود؛

۵. measure: فروپاشی به پایه محاسباتی.

اثر بر خروجی: برخلاف مدار Independent، $|\psi\rangle$ درهم تنیده است و $P(s)$ دیگر فاکتورسازی پذیر نیست. گیت های $Z_i Z_j$ weight را بین های bitstring که بیت های i, j یکسان دارند جابه جا می کند. در نتیجه:

- توزیع احتمال «غنی تر» و حساس تر به نویز همبسته است؛
- baseline «بدون آموزش» برای نویز تجربی کمتر افت می کند (Independent برای 0.768 vs 0.853) — ساختار متفاوت توزیع؛
- آموزش MLP سخت تر می شود وقتی نویز train با مدار/نویز test ناسازگار باشد.

۲.۳.۱ سه مدل نویز خوانش

جدول ۲.۱: مدل های نویز در پروژه

نام	پیاده سازی	توضیح
synthetic	ReadoutError	$p_{01}, p_{10} \sim U[0.05, 0.15]$ یکسان روی
experimental_single qubit	ReadoutError	۴ کیوبیت مجزا per از $A^{(1)}, \dots, A^{(4)}$ تجربی
experimental_correlated	$p_{\text{noisy}} = p_{\text{ideal}}$	ماتریس 16×16 ؛ دستی

نویز مصنوعی (synthetic)

ماتریس flip برای هر کیوبیت:

$$A_{\text{syn}} = \begin{pmatrix} 1 - p_{01} & p_{01} \\ p_{10} & 1 - p_{10} \end{pmatrix}.$$

در Qiskit Aer:

```
readout_error = ReadoutError([[1-p01, p01], [p10, 1-p10]])
noise_model.add_readout_error(readout_error, [q])
```

نویز تک کیوبیتی تجربی

برای هر کیوبیت q :

```
A = np.loadtxt(f"assignment_matrix_q{q+1}.txt")
noise_model.add_readout_error(ReadoutError(A), [q])
```

Aer خطای خوانش را مستقل روی هر کیوبیت اعمال می کند؛ یعنی کانال کلی فاکتورسازی شده است.

نویز همبسته تجربی

Qiskit Aer از اعمال مستقیم ماتریس 16×16 به عنوان ReadoutError روی چهار کیوبیت پشتیبانی نمی کند. بنابراین:

$$\mathbf{p}_{\text{noisy}} = \mathbf{p}_{\text{ideal}} M, \quad (6.1)$$

که $\mathbf{p}_{\text{ideal}} \in \mathbb{R}^{1 \times 16}$ بردار احتمال حالت های آماده (قبل از خوانش) و M همان ماتریس استخراج شده از داده تجربی است.

نکته ۱.۱ (چرا Aer از 16×16 پشتیبانی نمی کند). ReadoutError در Qiskit Aer برای هر مجموعه کیوبیت یک ماتریس stochastic تعریف می کند که سطرهای آن حالت های آماده آن زیرمجموعه و ستون ها حالت های اندازه گیری هستند. برای 4 کیوبیت، یک ماتریس 16×16 کانال readout کامل را توصیف می کند، اما API استاندارد add_readout_error این را به صورت کانال مشترک روی همه کیوبیت ها به درستی برای ماتریس های همبسته پیاده نمی کند. بنابراین در این پروژه، شبیه سازی مدار بدون نویز انجام شده و سپس معادله (6.1) روی بردار احتمال اعمال می شود — معادل اعمال کانال readout کلاسیک پس از اندازه گیری ایده آل.

۳.۳.۱ شبیه سازی و تبدیل شمارش به احتمال

مدار با AerSimulator و shots=1024 اجرا می شود. تابع counts_to_probs_4q:

$$p_i = \frac{\text{count}(s_i)}{\sum_j \text{count}(s_j)}, \quad i = \text{int}(s_i, 2).$$

خط لوله تولید دیتاست (generate_dataset):

$$1. \theta \sim U[0, \pi]^4$$

$$2. p_{ideal} = \text{simulate}(\text{circuit}, \text{noise no})$$

$$3. p_{noisy} \Rightarrow \text{اعمال نویز}$$

$$4. \text{ذخیره: } X \leftarrow p_{noisy}, Y \leftarrow p_{ideal}, \theta \leftarrow \text{THETAS}$$

دیتاست‌ها در DataTrain/ با ساختار:

DataTrain/

```
independent/ {synthetic, experimental_single, experimental_correlated}/  
zz_featuremap/ {synthetic, experimental_single, experimental_correlated}/
```

هر پوشه شامل X_train.txt، Y_train.txt، theta_train.txt و مجموعه‌های validation و test (4500/1500/1500 نمونه).

۴.۳.۱ مدل یادگیری ماشین (MLP_4Q)

شبکه PyTorch:

$$16 \xrightarrow{\text{ReLU}} 128 \xrightarrow{\text{ReLU}} 256 \xrightarrow{\text{ReLU}} 128 \xrightarrow{\text{Softmax}} 16.$$

ورودی: p_{noisy} (۱۶ بعد) هدف: p_{ideal} (۱۶ بعد).

آموزش: Adam با $lr = 10^{-3}$ ، $batch_size=64$ ، $epochs=51$ ؛ زیان KLDivLoss (به جز فاز 3_2) که MSELoss.

نکته ۲.۱ (تفسیر وظیفه ML). مدل $\hat{p} = f_{\theta}(p_{noisy})$ تلاش می‌کند توزیع ایده‌آل را از توزیع نویزی بازسازی کند. این یک مسئله *mitigation error readout* است، نه طبقه‌بندی حالت. baseline «بدون آموزش» یعنی $\hat{p} = p_{noisy}$.

۵.۳.۱ معیار fidelity: مبانی فیزیکی و کاربرد در پروژه

تعریف ریاضی

برای دو بردار احتمال p (مرجع / ایده‌آل) و q (نویزی یا پیش‌بینی شده):

$$F(p, q) = \left(\sum_{i=0}^{15} \sqrt{p_i q_i} \right)^2. \quad (7.1)$$

این کمیت ضریب **Bhattacharyya** به توان ۲ است.

تفسیر فیزیکی

- اگر حمایت دو توزیع گسسته disjoint باشد. $F = 0$ ؛ $p = q$ iff $F = 1$
- $\sqrt{F}$ همان classical fidelity یا overlap است؛ برای state خالص $|\psi\rangle$: $F = |\langle\psi|\phi\rangle|^2$
- F روی‌های peak مشترک حساس است: spread نویز به حالت‌های اشتباه، F را کاهش می‌دهد.
- برخلاف accuracy تک‌کیوبیتی در بخش اول، F کل بردار 16 بعدی را می‌سنجد.

کاربرد در ارزیابی

۱. Baseline: $F(p_{\text{ideal}}, p_{\text{noisy}})$

۲. پس از MLP: $F(p_{\text{ideal}}, \hat{p})$

۳. گزارش جدول: میانگین روی $N_{\text{test}} = 1500$ نمونه.

معیارهای کمکی:

$$L_1: \quad \|p - q\|_1 = \sum_i |p_i - q_i|, \quad (8.1)$$

$$KL: \quad D_{KL}(p \parallel q) = \sum_i p_i \log \frac{p_i}{q_i}. \quad (9.1)$$

۶.۳.۱ طراحی آزمایش: فازهای آموزش و ارزیابی

جدول ۳.۱ طرح کامل آزمایش را نشان می‌دهد. سطر = نوع مدار + نویزی که مدل روی آن آموزش دیده؛ ستون = نوع نویز در مجموعه آزمون.

جدول ۳.۱: طرح آزمایش: فازها، مدار، نویز آموزش و دیتاست‌ها

فاز	مدار	نویز آموزش	مدل	تعداد نمونه train
۰	Independent	بدون آموزش (Identity)	—	—
۱	Independent	synthetic	MLP	۴۵۰۰
۰ ۲	Independent	exp. single	MLP	۴۵۰۰
۱ ۲	Independent	exp. correlated	MLP	۴۵۰۰
۰ ۳	ZZ FeatureMap	synthetic	MLP	۴۵۰۰
۱ ۳	ZZ FeatureMap	exp. single	MLP	۴۵۰۰
۲ ۳	ZZ FeatureMap	exp. correlated	MLP	۴۵۰۰

۴.۱ مرجع API های Qiskit برای خطای خوانش

جدول ۴.۱: دستورات Qiskit استفاده‌شده در پروژه

نقش	API
ساخت مدار (measure, ZZFeatureMap, Ry)	QuantumCircuit
شبیه‌سازی نمونه‌گیری با shots	AerSimulator
نگهداری مدل نویز	NoiseModel
کانال readout با ماتریس A stochastic	ReadoutError(A)
add_readout_error(err, [q]) اتصال خطا به کیوبیت q	
بهینه‌سازی مدار برای backend	transpile(qc, sim)
هیستوگرام اندازه‌گیری	result.get_counts()
مدار map feature استاندارد QML	zz_feature_map

ماتریس ReadoutError باید $2^n \times 2^n$ برای n کیوبیت باشد و هر سطر جمع 1 داشته باشد — همان قرارداد معادلات (۳.۱) و (۴.۱).

۵.۱ جدول مقایسه نتایج و تحلیل

جدول ۵.۱ میانگین fidelity (FidelityMean) را گزارش می‌کند: مقایسه خروجی مدل (یا ورودی خام در حالت «بدون آموزش») با P_{ideal} .

جدول ۵.۱: میانگین fidelity: سطر = (مدار، نویز آموزش)، ستون = نویز آزمون

مدار	نویز آموزش	Synthetic	Exp. Single	Exp. Correlated
Independent	بدون آموزش	۹۰۷.۰	۷۶۸.۰	۷۶۳.۰
	Synthetic	۹۷۹.۰	۸۲۹.۰	۸۲۱.۰
	Exp. Single	۸۹۴.۰	۹۷۷.۰	۹۷۲.۰
	Exp. Correlated	۸۷۴.۰	۹۵۸.۰	۹۷۱.۰
ZZ FeatureMap	بدون آموزش	۹۳۸.۰	۸۵۳.۰	۸۶۱.۰
	Synthetic	۹۷۲.۰	۸۹۲.۰	۹۰۰.۰
	Exp. Single	۸۴۸.۰	۹۳۴.۰	۹۴۲.۰
	Exp. Correlated	۸۴۱.۰	۹۲۲.۰	۹۶۳.۰

۱.۵.۱ تحلیل نظام‌وار نتایج

ردیف «بدون آموزش»

این مقادیر فاصله ذاتی p_{noisy} از p_{ideal} را بدون هیچ مدل ML نشان می‌دهند:

- نویز synthetic کم‌ترین افت را دارد ($0.91 \approx 0.94 - F$): های flip تصادفی ملایم، ساختار احتمال را تا حد زیادی حفظ می‌کنند.
- نویزهای تجربی (single و correlated) افت شدیدتری دارند ($0.76 \approx 0.86 - F$): نویز واقعی سخت‌تر و غیرایده‌آل‌تر است.
- مدار ZZ کمی مقاوم‌تر است (0.938 vs 0.907 برای synthetic)؛ احتمالاً به دلیل توزیع احتمال متمرکزتر یا ساختار متفاوت.

هم‌راستایی نویز آموزش و آزمون (قطری جدول)

وقتی نویز آموزش با نویز آزمون هم‌خوان است، بهترین fidelity حاصل می‌شود:

- آموزش synthetic $\Rightarrow$ تست synthetic: 0.972 / 0.979
- آموزش exp. single $\Rightarrow$ تست exp. single: 0.934 / 0.977
- آموزش exp. correlated $\Rightarrow$ تست exp. correlated: 0.963 / 0.971

این الگو تأیید می‌کند که pipeline به‌درستی پیاده شده: مدل می‌تواند mapping inverse نویز را یاد بگیرد وقتی توزیع train/test سازگار است.

تعمیم بین انواع نویز (خارج از قطری)

- آموزش synthetic روی تست exp. single: 0.829 — تعمیم متوسط؛ مدل synthetic نمی تواند تمام جزئیات نویز واقعی را پوشش دهد.
- آموزش exp. correlated روی تست exp. single: 0.958 — تعمیم خوب از همبسته به تک کیوبیتی؛ مدل همبسته اطلاعات بیشتری دارد.
- آموزش exp. single روی تست exp. correlated: 0.942 / 0.972 — تعمیم قوی؛ نویز همبسته «سخت تر» اما مدل single-qubit بخش بزرگی را capture می کند.

تأثیر نوع مدار

- برای Independent + آموزش exp. single: بهترین fidelity روی تست single (0.977).
- برای ZZ FeatureMap + آموزش exp. correlated: بهترین fidelity روی تست correlated (0.963) — بالاترین مقدار در ستون correlated برای ZZ.
- آموزش exp. single روی ZZ عملکرد ضعیف تری روی synthetic (0.848) دارد: mismatch بین مدار درهم تنیده و نویز ساده synthetic.

نتیجه گیری عملی از جدول

۱. برای **mitigation واقعی** مدل باید روی همان نوع نویز سخت افزار آموزش ببیند؛ experimental_correlated اولویت دارد.
۲. نویز **synthetic** برای debug مناسب است، جایگزین تجربی نیست.
۳. **MLP** در حالت matched بهبود $\Delta F \approx 0.07 - 0.21$ نسبت به baseline ایجاد می کند (جدول ۶.۱).
۴. تفاوت M و کرونگر در نتایج دیده می شود: ستون $\text{Single} \neq \text{Correlated}$.

جدول بهبود نسبت به baseline

جدول ۶.۱ افزایش fidelity نسبت به ردیف «بدون آموزش» (Identity) را برای هر ستون آزمون نشان می دهد.

جدول ۶.۱: بهبود fidelity (ΔF) نسبت به baseline «بدون آموزش»، در حالت matched (نویز train test) =

ΔF	$F_{\text{train no}}$	نویز آموزش/آزمون	مدار
۰.۷۲.۰+	۹۰۷.۰	Synthetic	Independent
۲۰۹.۰+	۷۶۸.۰	Exp. Single	Independent
۲۰۸.۰+	۷۶۳.۰	Exp. Correlated	Independent
۰.۳۴.۰+	۹۳۸.۰	Synthetic	ZZ FeatureMap
۰.۸۱.۰+	۸۵۳.۰	Exp. Single	ZZ FeatureMap
۱۰۲.۰+	۸۶۱.۰	Exp. Correlated	ZZ FeatureMap

نکات تکمیلی:

- بیشترین بهبود برای Independent + نویز تجربی ($\Delta F \approx 0.21$): فضای احتمال ساده‌تر، مدل راحت‌تر map inverse را یاد می‌گیرد.
- **correlated: + ZZ** baseline بالاتر (0.861) اما ΔF کمتر (0.102): مدار درهم‌تنیده سخت‌تر است، با این حال $F = 0.963$ بالاترین fidelity در ستون correlated است.
- آسیب **mismatch: ZZ** + exp. single train + synthetic test $\Rightarrow F = 0.848$ پایین‌تر از baseline 0.938: آموزش روی نویز اشتباه می‌تواند ضرر بزند.
- **single: $\rightarrow$ correlated** + Independent train $F = 0.958$ روی single (فقط 0.019 کمتر از matched 0.977) — مدل همبسته اطلاعات کافی برای single دارد.
- **correlated سخت‌ترین**: بدون آموزش، $F \approx 0.76$ — 0.86 ؛ با آموزش matched به -0.96 — 0.97 می‌رسد — همبستگی readout اصلی چالش است.
- **symmetry** نداشتن جدول طبیعی است: symmetric swap train/test نیست چون نویزها مدل‌های فیزیکی متفاوتی هستند.

۶.۱ قراردادهای حیاتی پروژه

۱. ترتیب بیت: معادله (۱.۱) در همه بخش‌ها یکسان بماند.
۲. قرارداد **Qiskit** برای M : $M_{ij} = P(\text{measured} = j \mid \text{prepared} = i)$ ؛ سطرها stochastic.
۳. نویز همبسته: همیشه با `apply_correlated_readout_noise` دستی اعمال شود، نه از طریق `NoiseModel`.

۴. ترتیب اجرا: ابتدا `readout_matrix.ipynb` $\Rightarrow$ سپس `noisy_4q_zzfeaturemap.ipynb`.

۵. بردار احتمال: همیشه ۱۶ بعدی؛ $\sum_i p_i = 1$.

۷.۱ جمع‌بندی

این پروژه یک خط لوله کامل از داده خام IQ (شکل ۱.۱) تا *mitigation* یادگیری ماشین برای نویز خوانش چهار کیوبیتی ارائه می‌دهد. بخش اول ماتریس‌های نویز را با LDA و شمارش همبسته استخراج می‌کند. بخش دوم دو مدار (شکل‌های ۲.۱ و ۳.۱) را تحت سه مدل نویز شبیه‌سازی کرده و MLP را با معیار *fidelity* فیزیکی معنادار ارزیابی می‌کند. نتایج نشان می‌دهد هم‌راستایی نویز `train/test` کلید موفقیت است؛ نویز همبسته تجربی برای مدل‌سازی واقع‌گرایانه ضروری است و آموزش روی نویز نادرست — به‌ویژه برای مدار ZZ — می‌تواند عملکرد را از `baseline` پایین‌تر کند.

Bibliography