

گزارش فنی پروژه نويز خوانش چهار کیوبیتی

۱.۰ هدف و تصویر کلی

هدف این گزارش، مستندسازی یک پایپلاین کامل برای مدل سازی نويز خوانش در یک سامانه چهار کیوبیتی است. پروژه از داده های خام تجربی IQ شروع می شود، از روی آن ها ماتریس های خطای خوانش را استخراج می کند، سپس این نویزها را روی مدارهای کوانتومی اعمال می کند و در نهایت با یک مدل یادگیری ماشین تلاش می کند توزیع احتمال نویزی را به توزیع ایده آل بازگرداند.

دو فایل اصلی پروژه چنین نقشی دارند:

- `readout_matrix.ipynb`: بارگذاری داده های تجربی، آموزش تفکیک کننده IQ، استخراج ماتریس های 2×2 و 16×16 ؛

- `noisy_4q_zzfeaturemap.ipynb`: ساخت مدار، اعمال سه نوع نویز، تولید دیتاست، آموزش MLP و ارزیابی با `fidelity`.


در کل پروژه یک قرارداد مهم حفظ می شود: ماتریس نویز خوانش به صورت

$$A_{ij} = P(\text{measured} = j \mid \text{prepared} = i) \quad (1)$$

تعریف شده است. بنابراین سطرها حالت آماده سازی و ستون ها حالت اندازه گیری هستند و هر سطر جمع یک دارد. این همان قرارداد مورد استفاده در `Qiskit ReadoutError` است.

۲.۰ معماری کلی خط لوله پروژه

پروژه یک مسیر پیوسته از داده خام تا ارزیابی mitigation دارد. شکل ۱ این مسیر را به صورت یک سیستم واحد نشان می‌دهد؛ نه چند آزمایش جدا.



شکل ۱: معماری کلی خط لوله: از داده IQ تا استخراج ماتریس نویز، تولید توزیع ایده‌آل/نویزی، miti- gation با MLP و ارزیابی.

دو شاخه اصلی:

۱. شاخه کالیبراسیون: داده IQ → LDA → ماتریس‌های نویز؛

۲. شاخه mitigation: مدار کوانتومی $P_{ideal} \rightarrow P_{noisy}$ و $P_{ideal} \rightarrow P_{hat_{ideal}}$ با MLP.

شاخه اول «مدل نویز سخت‌افزار» را می‌سازد؛ شاخه دوم از آن برای تولید دیتاست و ارزیابی استفاده می‌کند.

۳.۰ داده‌های تجربی IQ

۱.۳.۰ ساختار فایل‌ها

داده‌های تجربی در پوشه quadrature_data_4qubits قرار دارند. برای هر یک از ۱۶ حالت پایه محاسباتی یک فایل وجود دارد؛ از 0000.txt تا 1111.txt. هر فایل چهار خط دارد؛ هر خط مربوط

به یک کیوبیت است و شامل ۱۰۰۰ نمونه مختلط از نوع

$$z = I + iQ$$

است. بنابراین برای هر حالت آماده‌سازی، ۱۰۰۰ shot و برای کل پروژه

$$16 \times 1000 = 16000$$

نمونه چهارکیوبیتی داریم. پس از بارگذاری:

$$X \in \mathbb{C}^{16000 \times 4}, \quad Y \in \{0, 1\}^{16000 \times 4}.$$

در این نمایش، $X[n, q]$ نمونه IQ کیوبیت q در shot شماره n و $Y[n, q]$ بیت آماده‌سازی همان کیوبیت است.

۲.۳.۰ برچسب‌گذاری و ترتیب بیت‌ها


برچسب‌ها از نام فایل به دست می‌آیند. در کد، تابع `bits_from_filename` نام فایل را خوانده و برای سازگاری با ترتیب داخلی پروژه، بیت‌ها را معکوس می‌کند. قرارداد اندیس‌گذاری حالت‌ها چنین است:

$$i = b_1 + 2b_2 + 4b_3 + 8b_4. \quad (۲)$$

پس b_1 کم‌ارزش‌ترین بیت است و b_4 پرازش‌ترین بیت. این قرارداد باید در همه بخش‌ها، از ساخت ماتریس نویز تا تبدیل شمارش‌های Qiskit به بردار احتمال، یکسان بماند.

۳.۳.۰ ابرهای IQ و معنای فیزیکی آن‌ها

در اندازه‌گیری dispersive، خروجی هر shot یک نقطه در صفحه IQ است. اگر کیوبیت در حالت $|0\rangle$ آماده شده باشد، نقاط باید اطراف یک ابر و اگر در $|1\rangle$ آماده شده باشد اطراف ابر دیگری قرار گیرند. هرچه این دو ابر جداتر باشند، fidelity readout بالاتر است. همپوشانی ابرها همان ناحیه‌ای است که در آن تفکیک‌کننده ممکن است 0 را 1 یا 1 را 0 تشخیص دهد.



شکل ۲: ابرهای IQ برای دو حالت چهارکیوبیتی 1010 و 0101. هر پنل مربوط به یک کیوبیت است. جدایی و همپوشانی ابرها نشان می‌دهد خطای خوانش برای هر کیوبیت چقدر است و آیا crosstalk بین کیوبیت‌ها وجود دارد یا نه.

شکل ۲ چند نکته مهم را نشان می‌دهد. نخست، جدایی ابرها برای همه کیوبیت‌ها یکسان نیست، پس ماتریس‌های تک‌کیوبیتی نباید الزاماً مشابه باشند. دوم، شکل ابرها فقط تابع بیت همان کیوبیت نیست و حالت کلی چهارکیوبیتی هم می‌تواند مرکز یا پراکندگی ابر را تغییر دهد. این رفتار نشانه‌ای از crosstalk و دلیل اصلی نیاز به ماتریس همبسته 16×16 است.

۴.۰ استخراج ماتریس‌های نویز خوانش

۱.۴.۰ مدل Linear Discriminant Analysis

در بخش اول پروژه، برای هر کیوبیت یک مدل Linear Discriminant Analysis یا LDA آموزش داده شده است. ورودی مدل برای کیوبیت q بردار دوبعدی

$$\mathbf{x} = (I, Q)^T$$

و برچسب آن 0 یا 1 است. داده‌ها با train_test_split و نسبت 80/20 تقسیم می‌شوند و ویژگی‌ها قبل از آموزش با StandardScaler نرمال‌سازی می‌شوند.

LDA فرض می‌کند دو کلاس 0 و 1 در صفحه IQ تقریباً توزیع گاوسی با کواریانس مشترک دارند. برای کلاس k تابع امتیاز به صورت

$$\delta_k(\mathbf{x}) = \mathbf{x}^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log \pi_k \quad (۳)$$

نوشته می‌شود. در این رابطه μ_k میانگین کلاس، Σ کواریانس مشترک و π_k prior کلاس است. مدل نمونه را به کلاسی نسبت می‌دهد که δ_k بزرگ‌تری دارد. برای دو کلاس، مرز تصمیم یک خط در صفحه

IQ است:

$$\mathbf{w}^T \mathbf{x} + w_0 = 0, \quad \mathbf{w} = \Sigma^{-1}(\mu_1 - \mu_0).$$

انتخاب LDA برای این پروژه منطقی است، چون مسئله تفکیک IQ دوبعدی است، مدل پایدار و قابل تفسیر است و هدف اصلی صرفاً بیشینه کردن accuracy نیست؛ هدف ساختن تخمینی پایدار از احتمال‌های $P(m|p)$ است. در نوت‌بوک، QDA نیز آزمایش شده است، اما LDA به عنوان گزینه ساده‌تر و پایدارتر انتخاب شده است.

۲.۴.۰ ماتریس‌های تک‌کیوبیتی 2×2

پس از آموزش مدل کیوبیت q ، خروجی model روی داده test با برچسب واقعی مقایسه می‌شود. ماتریس تخصیص تک‌کیوبیتی از ماتریس confusion نرمال‌شده ساخته می‌شود:

$$A^{(q)} = \begin{pmatrix} P(m_q = 0|p_q = 0) & P(m_q = 1|p_q = 0) \\ P(m_q = 0|p_q = 1) & P(m_q = 1|p_q = 1) \end{pmatrix}. \quad (۴)$$

در این ماتریس، عناصر قطری fidelity خوانش حالت‌های 0 و 1 هستند و عناصر غیرقطری احتمال خطای flip در خوانش را نشان می‌دهند. برای مثال، در یکی از اجراها ماتریس کیوبیت ۱ تقریباً چنین بوده است:

$$A^{(1)} \approx \begin{pmatrix} 0.794 & 0.206 \\ 0.369 & 0.631 \end{pmatrix}.$$

این یعنی وقتی کیوبیت ۱ در $|0\rangle$ آماده شده، حدود 20.6% احتمال دارد 1 خوانده شود، و وقتی در $|1\rangle$ آماده شده، حدود 36.9% احتمال دارد 0 خوانده شود.

۳.۴.۰ ماتریس همبسته 16×16

برای ساخت ماتریس کامل، چهار مدل تک‌کیوبیتی روی کل دیتاست اعمال می‌شوند و برای هر shot یک بیت‌رشته پیش‌بینی شده $\hat{\mathbf{b}}$ به دست می‌آید. سپس برای هر حالت آماده‌سازی i و حالت اندازه‌گیری j شمارش انجام می‌شود:

$$M_{ij} = \frac{1}{N_i} \sum_{n: Y_n = \text{bits}(i)} \mathbb{1}[\text{bits_to_int}(\hat{\mathbf{b}}_n) = j]. \quad (۵)$$

این ماتریس همان کانال کلاسیک خوانش چهارکیوبیتی است:

$$\mathbf{P}_{\text{measured}} = \mathbf{P}_{\text{prepared}} M.$$

اعتبارسنجی اصلی این است که برای هر سطر

$$\sum_{j=0}^{15} M_{ij} = 1.$$

در اجرای موجود، میانگین عناصر قطری این ماتریس حدود

$$\bar{F}_{\text{diag}} = \frac{1}{16} \sum_i M_{ii} \approx 0.385$$

بوده است. این عدد نشان می‌دهد خوانش چهارکیوبیتی دقیقاً به همان حالت آماده‌شده، به دلیل ضرب خطاهای چند کیوبیت و همبستگی‌ها، fidelity نسبتاً پایینی دارد.

۴.۴.۰ اعتبارسنجی ماتریس‌های نویز

استخراج ماتریس کافی نیست؛ باید مطمئن شویم خروجی یک کانال احتمال معتبر است. در غیر این صورت نمی‌توان آن را در شبیه‌سازی یا mitigation استفاده کرد.

بررسی‌های اصلی:

$$A_{ij} \geq 0 \quad (\text{غیرمنفی بودن}) \quad (۶)$$

$$\sum_j A_{ij} = 1 \quad (\text{نرمال‌سازی سطری}) \quad (۷)$$

$$\bar{A}_{ii} = \frac{1}{16} \sum_i A_{ii} \quad (\text{رفتار قطری}) \quad (۸)$$

$$M \neq A^{(1)} \otimes A^{(2)} \otimes A^{(3)} \otimes A^{(4)} \quad (\text{عدم استقلال}) \quad (۹)$$

این اعتبارسنجی تضمین می‌کند ماتریس استخراج‌شده را می‌توان مستقیماً به عنوان کانال readout در تولید $\mathbf{p}_{\text{noisy}}$ استفاده کرد. اگر قرارداد سطری Qiskit رعایت نشود یا ordering بیت‌ها جابه‌جا شود، ماتریس از نظر ریاضی stochastic به نظر می‌رسد اما فیزیکاً اشتباه خواهد بود.

جدول ۱: چک لیست اعتبارسنجی ماتریس نویز

معنی فیزیکی	شرط	بررسی
احتمال منفی معنا ندارد	$A_{ij} \geq 0$	غیرمنفی
هر حالت آماده به توزیع کامل می رود	$\sum_j A_{ij} = 1$	نرمال سازی
میانگین fidelity خوانش	$\bar{A}_{ii} \approx 0.39$	قطری
وجود correlation / crosstalk	$M \neq M_{\text{indep}}$	مقایسه

۵.۴.۰ چرا ماتریس 16×16 برابر کرونکر چهار ماتریس 2×2 نیست؟

اگر خطای خوانش چهار کیوبیت کاملاً مستقل بود، ماتریس کامل از کرونکر محصول ماتریس های تک کیوبیتی به دست می آمد:

$$M_{\text{indep}} = A^{(4)} \otimes A^{(3)} \otimes A^{(2)} \otimes A^{(1)}. \quad (10)$$

اما این فقط تحت فرض استقلال معتبر است. در داده تجربی، ابرهای IQ نشان می دهند حالت دیگر کیوبیت ها می تواند توزیع خوانش یک کیوبیت را جابه جا کند. بنابراین

$$M \neq M_{\text{indep}}$$

و همین اختلاف حامل اطلاعات فیزیکی مهم درباره crosstalk خطاهای همبسته و غیرقابل فاکتورسازی بودن خوانش است.

به بیان دیگر، ماتریس های 2×2 پاسخ متوسط هر کیوبیت را جداگانه خلاصه می کنند، اما ماتریس 16×16 پاسخ کل register را به صورت مشترک ثبت می کند. انتظار برابری این دو فقط در یک مدل ایده آل مستقل درست است، نه در سخت افزار واقعی.


۵.۰ مدارهای کوانتومی استفاده شده در بخش دوم

در بخش دوم، از دو خانواده مدار برای تولید توزیع احتمال ایده آل و نویزی استفاده شده است. در هر نمونه، بردار پارامتر

$$\theta = (\theta_1, \theta_2, \theta_3, \theta_4)$$

به طور تصادفی از بازه $[0, \pi]^4$ انتخاب می شود.

۱.۵.۰ مدار مستقل RY



شکل ۳: مدار مستقل شامل چهار گیت $R_y(\theta_i)$ و اندازه‌گیری نهایی. این مدار درهم‌تنیدگی ایجاد نمی‌کند و توزیع خروجی آن فاکتورسازی شده است.

در این مدار روی هر کیوبیت فقط یک گیت R_y اعمال می‌شود:

$$R_y(\theta) = e^{-i\theta Y/2}. \quad (۱۱)$$

اثر آن روی حالت اولیه $|0\rangle$ چنین است:


$$R_y(\theta)|0\rangle = \cos\frac{\theta}{2}|0\rangle + \sin\frac{\theta}{2}|1\rangle. \quad (۱۲)$$

پس احتمال اندازه‌گیری ۱ برابر $\sin^2(\theta/2)$ و احتمال اندازه‌گیری ۰ برابر $\cos^2(\theta/2)$ است. چون هیچ گیت دوکیوبیتی وجود ندارد، حالت کلی جدایی‌پذیر است و برای بیت‌رشته $s = s_1 s_2 s_3 s_4$:

$$P(s) = \prod_{k=1}^4 \left[\cos^2 \frac{\theta_k}{2} \right]^{1-s_k} \left[\sin^2 \frac{\theta_k}{2} \right]^{s_k}. \quad (۱۳)$$

این مدار benchmark ساده‌ای فراهم می‌کند: اگر mitigation روی این مدار هم خوب کار نکند، روی مدارهای پیچیده‌تر قابل اعتماد نخواهد بود.

۲.۵.۰ مدار ZZ FeatureMap



شکل ۴: مدار ZZFeatureMap چهارکیوبیتی. این مدار شامل لایه‌های Hadamard، گیت‌های فاز و بلوک‌های ZZ بین جفت کیوبیت‌هاست و توزیع احتمال غیرقابل فاکتورسازی تولید می‌کند.

مدار دوم با تابع `zz_feature_map` در Qiskit ساخته شده است. نقش گیت‌ها چنین است:

- **Hadamard**: حالت $|0\rangle$ را به $|+\rangle$ می‌برد و superposition اولیه ایجاد می‌کند؛
- **gate Phase**: اطلاعات پارامتر θ_i را به فاز حالت‌ها وارد می‌کند؛
- **بلوک‌های ZZ**: برهم‌کنش‌های دوتایی از نوع $Z_i Z_j$ ایجاد می‌کنند و فاز حالت‌ها را به صورت وابسته به جفت ویژگی‌ها تغییر می‌دهند؛
- **Measurement**: توزیع احتمال روی ۱۶ حالت پایه را تولید می‌کند.

در پیاده‌سازی Qiskit، برهم‌کنش‌های ZZ معمولاً با الگوی CNOT-P-CNOT ساخته می‌شوند. این بلوک معادل یک فاز شرطی دوتایی است و باعث می‌شود توزیع خروجی دیگر به صورت ضرب چهار توزیع تک‌کیوبیتی نوشته نشود. به همین دلیل، ZZ FeatureMap تست سخت‌تری برای مدل mitigation است: هم مدار هم نویز می‌توانند همبستگی ایجاد کنند.

۶.۰ سه مدل نویز خوانش

۱.۶.۰ نویز مصنوعی

در حالت synthetic، یک ماتریس flip ساده برای همه کیوبیت‌ها استفاده می‌شود:

$$A_{\text{syn}} = \begin{pmatrix} 1 - p_{01} & p_{01} \\ p_{10} & 1 - p_{10} \end{pmatrix}. \quad (۱۴)$$

در تولید دیتاست، p_{01} و p_{10} معمولاً از بازه $[0.05, 0.15]$ انتخاب می‌شوند. در Qiskit Aer این نویز با ReadoutError و NoiseModel روی هر کیوبیت اعمال می‌شود.

۲.۶.۰ نویز تجربی تک کیوبیتی

در حالت experimental_single، چهار ماتریس $A^{(q)}$ که در بخش اول استخراج شده‌اند بارگذاری می‌شوند و برای هر کیوبیت به صورت مستقل به NoiseModel داده می‌شوند:

```
readout_error = ReadoutError(A_q)
noise_model.add_readout_error(readout_error, [q])
```

این روش خطای واقعی هر کیوبیت را لحاظ می‌کند، اما همچنان فرض می‌کند کانال کلی فاکتورسازی شده است.

۳.۶.۰ نویز تجربی همبسته

در حالت experimental_correlated، از ماتریس کامل M استفاده می‌شود. چون Qiskit Aer برای این کاربرد، اعمال مستقیم ماتریس همبسته 16×16 را به صورت error readout چندکیوبیتی در جریان شبیه‌سازی استفاده نکرده است، نویز به شکل پس‌پردازش روی بردار احتمال اعمال می‌شود:

$$\mathbf{p}_{\text{noisy}} = \mathbf{p}_{\text{ideal}} M. \quad (۱۵)$$

این رابطه دقیقاً با قرارداد سطری ماتریس سازگار است: هر مؤلفه ایده‌آل p_i بین خروجی‌های اندازه‌گیری j طبق سطر M_{ij} پخش می‌شود.

۷.۰ تولید دیتاست، استراتژی آزمایش و مدل یادگیری ماشین

۱.۷.۰ استراتژی طراحی دیتاست‌ها

ساختار پوشه‌های DataTrain فقط یک سازماندهی فایل نیست؛ پشت آن یک منطق آزمایشی مشخص قرار دارد. در نسخه نهایی پروژه، نویز آموزش و آزمون منطبق در نظر گرفته می‌شود. هر مدل فقط روی همان کانال نویزی ارزیابی می‌شود که با آن آموزش دیده است. این انتخاب باعث می‌شود تحلیل نتایج مستقیم‌تر و از نظر فیزیکی معنادارتر باشد.

جدول ۲: منطق طراحی دیتاست در فازهای مختلف (ارزیابی با نویز منطبق)

Phase	Train	Validation	Test (matched)
0	—	—	Independent/ZZ × 3 noises (baseline)
1	Ind. + Synthetic	Ind. + Synthetic	Ind. + Synthetic
2_0	Ind. + Exp. Single	Ind. + Exp. Single	Ind. + Exp. Single
2_1	Ind. + Exp. Corr.	Ind. + Exp. Corr.	Ind. + Exp. Corr.
3_0	ZZ + Synthetic	ZZ + Synthetic	ZZ + Synthetic
3_1	ZZ + Exp. Single	ZZ + Exp. Single	ZZ + Exp. Single
3_2	ZZ + Exp. Corr.	ZZ + Exp. Corr.	ZZ + Exp. Corr.

منطق ارزیابی:

۱. فاز ۰: (baseline) مدل هویت؛ ارزیابی روی هر سه نویز برای سنجش شدت خام نویز؛

۲. فازهای ۱ تا ۳: آموزش و آزمون روی همان مدار و همان نویز؛

۳. مقایسه نهایی: برای هر (نویز، مدار)، baseline در برابر مدل آموزش دیده.

۲.۷.۰ خط لوله تولید دیتاست

برای هر نمونه دیتاست:

۱. بردار زاویه‌ها θ تصادفی تولید می‌شود؛

۲. مدار انتخاب شده ساخته می‌شود؛

۳. شبیه‌سازی بدون نویز انجام می‌شود و p_{ideal} به دست می‌آید؛

۴. یکی از سه نویز اعمال می‌شود و p_{noisy} تولید می‌شود؛

۵. ورودی و خروجی یادگیری ماشین ذخیره می‌شوند:

$$X = \mathbf{p}_{\text{noisy}}, \quad Y = \mathbf{p}_{\text{ideal}}.$$

هر بردار احتمال ۱۶ بعدی است و ترتیب مؤلفه‌ها مطابق حالت‌های ۰۰۰۰ تا ۱۱۱۱ است. دیتاست‌ها در ساختار

```
DataTrain/  
  independent/  
    synthetic/  
    experimental_single/  
    experimental_correlated/  
  zz_featuremap/  
    synthetic/  
    experimental_single/  
    experimental_correlated/
```

ذخیره می‌شوند. در اجرای اصلی، اندازه‌ها برای validation train و test به ترتیب ۴۵۰۰، ۱۵۰۰ و ۱۵۰۰ نمونه بوده است.

۳.۷.۰ نقش مدل MLP: تقریب کانال معکوس

مدل یادگیری ماشین یک شبکه کاملاً متصل است:

$$16 \rightarrow 128 \rightarrow 256 \rightarrow 128 \rightarrow 16.$$

لایه خروجی Softmax دارد تا $\hat{p}$ یک بردار احتمال معتبر باشد.

مدل MLP چیست و چه نیست:

- نیست classifier حالت $|s\rangle$ ؛

- نیست discriminator state روی IQ؛

• هست تقریب غیرخطی از $channel\ readout\ inverse$:

$$f_{\theta} \approx \mathcal{M}^{-1}, \quad \hat{\mathbf{p}}_{ideal} = f_{\theta}(\mathbf{p}_{noisy}).$$

مدل M^{-1} را به صورت صریح محاسبه نمی‌کند (ماتریس 16×16 لزوماً معکوس پذیر نیست). در عوض، یک نگاشت غیرخطی $\mathbb{R}^{16} \rightarrow \mathbb{R}^{16}$ یاد می‌گیرد که توزیع نویزی را به توزیع ایده‌آل نزدیک کند. از نظر علمی، این learned readout error mitigation است.

آموزش با Adam ($lr = 10^{-3}$)، size batch ۶۴ و حدود ۵۱ epoch انجام شده است. زیان اصلی KLDivLoss است؛ در فاز 3_2 از MSE Loss نیز استفاده شده است.

۸.۰ معیارهای ارزیابی و ها baseline

۱.۸.۰ Fidelity (وفاداری / شباهت) Bhattacharyya-based

برای دو توزیع احتمال p (ایده‌آل) و q (پیش‌بینی یا نویزی)، fidelity کلاسیک پروژه:

$$F(\mathbf{p}, \mathbf{q}) = \left(\sum_{i=0}^{15} \sqrt{p_i q_i} \right)^2 \quad (۱۶)$$

تعریف شده است. این کمیت معیار شباهت است نه فاصله: مقدار آن بین 0 و 1 است؛ $F = 1$ یعنی دو توزیع کاملاً یکسان‌اند. در فیزیک کوانتومی fidelity برای مقایسه حالت‌ها و توزیع‌های اندازه‌گیری بسیار رایج است.

از دید فیزیکی، fidelity میزان همپوشانی دو توزیع را می‌سنجد. اگر نویز خوانش بخشی از احتمال را از حالت‌های درست به حالت‌های اشتباه منتقل کند، overlap کم می‌شود. اگر مدل mitigation موفق باشد، $F(\mathbf{p}_{ideal}, \hat{\mathbf{p}})$ افزایش می‌یابد.

۲.۸.۰ Error L1 (فاصله منهتن / Variation-like) Total

$$L_1(\mathbf{p}, \mathbf{q}) = \sum_{i=0}^{15} |p_i - q_i| \quad (۱۷)$$

این معیار متقارن و ساده است: مجموع اختلاف مطلق بین دو توزیع. تفسیر مستقیم دارد: «در مجموع چقدر جرم احتمال جابه‌جا شده؟» ارتباط نزدیک با Total Variation Distance دارد ($TV = \frac{1}{2} L_1$). هرچه L_1 کوچک‌تر باشد، بازسازی بهتر است. برخلاف bounded fidelity، در $[0, 1]$ نیست (حداکثر 2 برای بردارهای احتمال).

۳.۸.۰ Divergence KL (واگرایی کولباک-لیبلر)

$$D_{KL}(\mathbf{p} \parallel \mathbf{q}) = \sum_{i=0}^{15} p_i \log \frac{p_i}{q_i} \quad (۱۸)$$

این معیار می‌پرسد: «اگر توزیع واقعی $\mathbf{p}$ باشد و ما آن را با $\mathbf{q}$ تقریب بزنیم، چقدر اطلاعات از دست می‌دهیم؟» ویژگی‌های مهم:

- نامتقارن است: $D_{KL}(\mathbf{p} \parallel \mathbf{q}) \neq D_{KL}(\mathbf{q} \parallel \mathbf{p})$ ؛
- وقتی q_i خیلی کوچک و p_i بزرگ باشد، مقدار به شدت رشد می‌کند؛
- در نواحی با p_i بالا به تفاوت‌های کوچک حساس است.

در این پروژه KLDivLoss برای آموزش MLP به کار رفته است، اما برای گزارش نهایی fidelity و L1 خواناترند.

۴.۸.۰ نقش هر معیار در پروژه

accuracy فقط می‌گوید بیشینه احتمال درست بوده یا نه؛ اما خروجی این پروژه یک توزیع کامل ۱۶ بعدی است. fidelity و L1 کل شکل توزیع را مقایسه می‌کنند.

جدول ۳: خلاصه معیارهای ارزیابی

معیار	نوع	بهرتر	کاربرد در پروژه
Fidelity	شباهت	بزرگ‌تر	گزارش نهایی، baseline مقایسه فازها
L_1	فاصله	کوچک‌تر	خطای مطلق توزیع، تفسیر فیزیکی
KL	واگرایی	کوچک‌تر	زیان آموزش (KLDivLoss)

۵.۸.۰ سه حالت مقایسه در ارزیابی

هدف پروژه «بالا بردن fidelity به هر قیمتی» نیست؛ هدف کاهش اثر نویز خوانش است. سه حالت زیر همیشه باید با هم مقایسه شوند:

$$F_{\text{raw}} = F(\mathbf{p}_{\text{ideal}}, \mathbf{p}_{\text{noisy}}) \quad \text{حالت ۱ — بدون mitigation} \quad (19)$$

$$F_{\text{MLP}} = F(\mathbf{p}_{\text{ideal}}, \hat{\mathbf{p}}) \quad \text{حالت ۲ — پس از MLP} \quad (20)$$

$$\Delta F = F_{\text{MLP}} - F_{\text{raw}} \quad \text{حالت ۳ — بهبود} \quad (21)$$

اگر F_{raw} از ابتدا نزدیک ۱ باشد (مثلاً 0.972 در ZZFeatureMap اولیه)، ΔF کوچک لزوماً به معنای مدل ضعیف نیست؛ ممکن است نویز از ابتدا کم اثر بوده باشد. بنابراین همیشه باید baseline خام و بهبود نسبی را با هم گزارش کرد.



شکل ۵: نمایش مفهومی بازسازی توزیع: ایده‌آل (چپ)، نویزی (وسط)، خروجی MLP (راست). هدف mitigation بازگرداندن شکل توزیع است، نه فقط بیشینه احتمال.

شکل ۵ نشان می‌دهد چرا fidelity معیار مناسب‌تری از accuracy است: حتی اگر argmax یکسان بماند، توزیع کامل تغییر کرده و mitigation باید این تغییر را جبران کند.

۹.۰ چالش‌ها، اصلاحات و نتایج

۱.۹.۰ چالش‌های پروژه و راه‌حل‌ها

پروژه فقط اجرای کد نبود؛ چند مشکل فنی در مسیر حل شد:

جدول ۴: چالش‌های اصلی و اصلاحات انجام‌شده

چالش	مشکل	راه‌حل
ترتیب بیت‌ها	جابه‌جایی سطر/ستون M	یکسان‌سازی bits_to_int در همه بخش‌ها
قرارداد Qiskit	transpose اشتباه ماتریس	$A_{ij} = P(m = j p = i)$ اعمال pM
ماتریس 16×16 ZZFeatureMap	Aer کانال همبسته کامل ندارد $F_{\text{raw}} \approx 0.972$ ، نویز کم‌اثر	apply_correlated_readout_noise افزایش reps به ۲
یکنواخت نویز train/test	ارزیابی cross-noise پیچیده	ارزیابی منطبق (matched)

۲.۹.۰ بررسی چالش یکنواختی ZZFeatureMap

در فرآیند تولید داده برای ارزیابی عملکرد مدل یادگیری، یکی از چالش‌های مهم مربوط به استفاده از مدار ZZFeatureMap مشاهده شد. در مراحل اولیه، داده‌های مربوط به این مدار با پارامترهای تصادفی و تعداد لایه کم ($\text{reps}=1$) تولید شدند. بررسی اولیه نشان داد که شباهت بین توزیع ایده‌آل و توزیع نویزی حتی پیش از اعمال مدل یادگیری بسیار زیاد است. به عنوان نمونه، مقدار فیدیلیتی خام بین داده‌های ایده‌آل و نویزی به صورت زیر مشاهده شد:

$$F_{\text{raw}} \approx 0.972 \quad (22)$$

این مقدار نشان می‌دهد که ورودی مدل (توزیع نویزی) و خروجی هدف (توزیع ایده‌آل) از ابتدا اختلاف بسیار کمی دارند. بنابراین اگر پس از آموزش مدل، مقدار فیدیلیتی بالایی مانند $F \approx 0.996$ مشاهده شود، این نتیجه الزاماً نشان‌دهنده توانایی بالای مدل در یادگیری تصحیح نویز نیست، زیرا بخشی از این عملکرد ناشی از شباهت اولیه داده‌ها است.

بررسی توزیع‌های تولید شده نشان داد که دلیل اصلی این رفتار، ماهیت خروجی مدار ZZFeatureMap با تنظیمات اولیه بود. این مدار در حالت $\text{reps} = 1$ برای بسیاری از انتخاب‌های تصادفی پارامترها، توزیع احتمال حالت‌های اندازه‌گیری شده‌ای نزدیک به توزیع یکنواخت ایجاد می‌کند. در چنین شرایطی، اثر نویز خوانش روی توزیع احتمال کاهش پیدا می‌کند، زیرا تغییرات ایجاد شده توسط نویز در مقایسه با توزیع تقریباً یکنواخت بسیار کوچک است.

به بیان دیگر، مسئله اصلی در این مرحله، عدم صحت مدل نویز یا فرآیند اعمال ماتریس نویز نبود؛ بلکه داده‌های تولید شده از مدار، ساختار کافی برای آشکار کردن اثر نویز را نداشتند. در نتیجه مدل یادگیری

ماشین عملاً با مسئله‌ای مواجه نبود که نیاز به اصلاح جدی داشته باشد.

برای رفع این مشکل، ساختار مدار تغییر داده شد و با افزایش عمق مدار از طریق افزایش تعداد لایه‌ها ($\text{reps} = 2$) تنوع بیشتری در توزیع‌های خروجی ایجاد شد. هدف از این تغییر، ایجاد یک تعادل مناسب بین دو عامل بود:

- وجود ساختار کافی در توزیع احتمال خروجی مدار، به طوری که مدل بتواند الگوهای کوانتومی را یاد بگیرد؛

- ایجاد اختلاف قابل مشاهده بین توزیع ایده‌آل و نویزی، به طوری که اثر نویز خوانش در داده‌ها باقی بماند.

پس از اصلاح مدار، مقدار خلوص توزیع‌های تولید شده افزایش یافت و در عین حال توزیع‌ها از حالت تقریباً یکنواخت خارج شدند. این تغییر باعث شد داده‌های تولید شده برای آموزش و ارزیابی مدل، چالش واقعی‌تری ایجاد کنند و عملکرد مدل در شرایط مختلف نویز قابل تفسیرتر باشد.

لازم به ذکر است که هدف در این پروژه، بیشینه کردن یا کمینه کردن مستقیم معیارهایی مانند Purity یا Fidelity نیست؛ بلکه هدف اصلی ایجاد دیتاست‌هایی است که در آن‌ها:

۱. مدارهای کوانتومی دارای ساختار قابل یادگیری باشند؛

۲. نویز خوانش بتواند تغییر قابل اندازه‌گیری در توزیع احتمال ایجاد کند؛

۳. مدل یادگیری مجبور به استخراج نگاهت بین توزیع نویزی و توزیع ایده‌آل باشد.

بنابراین اصلاح پارامترهای مدار ZZFeatureMap به عنوان یک مرحله ضروری در آماده‌سازی داده انجام شد تا ارزیابی مدل در مراحل بعدی پروژه، بازتاب واقعی‌تری از توانایی مدل در کاهش اثر نویز کوانتومی داشته باشد.

۳.۹.۰ جدول اصلی نتایج (ارزیابی با نویز منطبق)

در ارزیابی نهایی، هر مدل آموزش دیده فقط روی همان نویزی آزمون می‌شود که با آن آموزش دیده است. جدول ۵ baseline (بدون آموزش) را در برابر مدل آموزش دیده مقایسه می‌کند.

جدول ۵: میانگین fidelity روی test با نویز منطبق. train/test.

ΔF	Trained	Baseline	Noise	Circuit
۰.۷۲.۰+	۹۷۹.۰	۹۰۷.۰	Synthetic	Independent
۲۰۹.۰+	۹۷۷.۰	۷۶۸.۰	Single Exp.	
۲۰۸.۰+	۹۷۱.۰	۷۶۳.۰	Correlated Exp.	
۰.۳۴.۰+	۹۷۲.۰	۹۳۸.۰	Synthetic	FeatureMap ZZ
۰.۸۱.۰+	۹۳۴.۰	۸۵۳.۰	Single Exp.	
۱۰۲.۰+	۹۶۳.۰	۸۶۱.۰	Correlated Exp.	

۴.۹.۰ تحلیل baseline

ردیف baseline نشان می‌دهد نویز به تنهایی چقدر توزیع ایده‌آل را خراب می‌کند. برای مدار مستقل، fidelity نویز مصنوعی 0.907 است، اما برای نویزهای تجربی به حدود 0.76 افت می‌کند. این نشان می‌دهد نویز تجربی بسیار جدی‌تر از flip مصنوعی ساده است. برای مدار FeatureMap ZZ ها baseline کمی بالاترند؛ شکل توزیع این مدار با همین نویزها overlap بیشتری با ایده‌آل حفظ می‌کند.

۵.۹.۰ اثر آموزش با نویز منطبق

وقتی train و test روی همان کانال نویز باشند، مدل MLP به‌طور پایدار fidelity را بالا می‌برد:

- Independent/Synthetic: از 0.907 به 0.979؛
- Independent/Experimental Single: از 0.768 به 0.977؛
- Independent/Experimental Correlated: از 0.763 به 0.971؛
- ZZ/Experimental Correlated: از 0.861 به 0.963.

این الگو نشان می‌دهد مدل واقعاً نداشت معکوس کانال readout را یاد گرفته است. بیشترین بهبود ($\Delta F \approx 0.21$) برای نویزهای تجربی مدار مستقل است؛ جایی که baseline پایین‌تر بوده و فضای بیشتری برای mitigation وجود داشته.

۶.۹.۰ چرا ارزیابی منطبق؟

در نسخه اولیه پروژه، هر مدل روی هر سه نویز آزمون می‌شد (ماتریس 3×4). آن رویکرد برای مطالعه robustness مفید بود، اما تحلیل را پیچیده می‌کرد: گاهی مدل آموزش دیده روی نویز A وقتی روی نویز B

آزمون می‌شد، از *baseline* بدتر عمل می‌کرد (مثلاً ZZ/Exp. Single روی Synthetic: 0.848 fidelity در برابر 0.938 baseline). بنابراین در نسخه نهایی، ارزیابی فقط در حالت منطبق انجام می‌شود تا:

۱. سنجش مستقیم «آیا مدل کانال نویز را invert کرده؟»؛

۲. مقایسه منصفانه baseline در برابر trained؛

۳. گزارش ساده‌تر با جدول trained vs baseline برای هر (نویز، مدار).

۷.۹.۰ بهبود نسبت به baseline

جدول ۵ نشان می‌دهد بیشترین سود یادگیری ماشین در جایی است که نویز تجربی شدیدتر بوده است. در مدار مستقل، نویز تجربی fidelity را حدود 0.76 کرده و مدل آن را تا حدود 0.97 برگردانده است ($\Delta F \approx 0.21$). در مدار ZZها baseline بالاترند، اما مدل همچنان بهبود معنادار ($\Delta F \approx 0.03$ تا 0.10) ایجاد می‌کند.

۱۰.۰ محدودیت‌های فعلی پروژه

۱. مقیاس: فقط ۴ کیوبیت بررسی شده؛ برای $n > 4$ اندازه ماتریس $2^n \times 2^n$ به سرعت رشد می‌کند.

۲. وابستگی به کالیبراسیون: ماتریس‌های نویز snapshot فعلی سخت‌افزار هستند و drift زمانی لحاظ نشده.

۳. ارزیابی منطبق: در این گزارش فقط حالت matched train/test بررسی شده؛ generalization به نویز یا مدار دیگر در scope فعلی نیست.

۴. تقریب غیرخطی: MLP معکوس دقیق M نیست؛ distribution outside ممکن است ضعیف عمل کند.

۵. نویز فقط: readout error gate و decoherence در شبیه‌سازی لحاظ نشده‌اند.

بیان صریح این محدودیت‌ها اعتبار گزارش را بالا می‌برد و مسیر ادامه کار را روشن می‌کند.

۱۱.۰ نکات حساس و توصیه‌های عملی

۱. ترتیب بیت‌ها: قرارداد معادله (۲) باید در همه جا ثابت بماند. هر تغییر کوچک در ordering می‌تواند کل ماتریس 16×16 را جابه‌جا کند.
۲. قرارداد سطری ماتریس: همیشه $A_{ij} = P(m = j | p = i)$ است. بنابراین اعمال نویز همبسته به صورت $p_{ideal} M$ انجام می‌شود.
۳. ماتریس 16×16 را با کرونکر اشتباه نگیریم: کرونکر فقط مدل مستقل است؛ ماتریس تجربی کامل اطلاعات crosstalk و correlation را دارد.
۴. نویز مصنوعی کافی نیست: برای ارزیابی واقعی، باید حداقل از experimental_single و بهتر از آن از experimental_correlated استفاده شود.
۵. مدل mitigation باید با شرایط آزمون سازگار باشد: train و test باید روی همان کانال نویز باشند؛ در غیر این صورت حتی از baseline هم بدتر می‌شود.

۱۲.۰ جمع‌بندی نهایی

این پروژه یک مسیر کامل و قابل دفاع برای مطالعه نویز خوانش چهار کیوبیتی ساخته است (شکل ۱). در بخش اول، داده‌های خام IQ با LDA به بیت‌های اندازه‌گیری شده تبدیل می‌شوند و پس از اعتبارسنجی، ماتریس‌های تخصیص تک‌کیوبیتی و ماتریس همبسته 16×16 استخراج می‌شود.

در بخش دوم، سه نوع نویز روی دو مدار کوانتومی اعمال می‌شود. ارزیابی نهایی با نویز منطبق train/test انجام می‌شود: هر مدل فقط روی همان کانال نویزی آزمون می‌شود که با آن آموزش دیده است. مدل MLP نقش تقریب کانال معکوس readout را دارد و با KL fidelity و L1 ارزیابی می‌شود.

نتایج نشان می‌دهد mitigation در حالت منطبق بسیار مؤثر است، به‌ویژه برای نویز تجربی. baseline trained vs واقعی و آموزش/آزمون روی همان کانال نویز ضروری است.