

کاهش خطای Readout با الگوریتم‌های یادگیری ماشین

در سامانه‌های کوانتومی مبتنی بر کیوبیت، فرآیند Readout یا خوانش حالت کیوبیت یکی از منابع اصلی خطا محسوب می‌شود. حتی در شرایطی که عملیات منطقی (گیت‌ها) با دقت بالا انجام شوند، خطای خوانش می‌تواند دقت کلی سیستم را به‌طور قابل‌توجهی کاهش دهد. از این‌رو، کاهش خطای readout یکی از چالش‌های کلیدی در توسعه‌ی پردازنده‌های کوانتومی مقیاس‌پذیر است.

در سال‌های اخیر، الگوریتم‌های یادگیری ماشین به‌عنوان ابزاری قدرتمند برای بهبود فرآیند readout مطرح شده‌اند. این روش‌ها با بهره‌گیری از داده‌های تجربی و بدون نیاز به مدل‌سازی دقیق فیزیکی، می‌توانند الگوهای پنهان در سیگنال‌های اندازه‌گیری را استخراج کرده و دقت تشخیص حالت کیوبیت را افزایش دهند.

در بسیاری از پلتفرم‌ها (به‌ویژه کیوبیت‌های ابررسانا)، خوانش کیوبیت در dispersive regime انجام می‌شود. در این حالت، حالت کیوبیت باعث تغییر کوچکی در فرکانس تشدیدگر می‌شود و این تغییر از طریق اندازه‌گیری سیگنال‌های I و Q (مولفه‌های درفاز و درتعامد) استخراج می‌گردد.

مهم‌ترین منابع خطای readout عبارت‌اند از:

- نویز تقویت‌کننده‌ها و زنجیره‌ی اندازه‌گیری
- هم‌پوشانی توزیع آماری سیگنال‌های مربوط به حالت‌های $|0\rangle$ و $|1\rangle$
- محدودیت‌های زمانی در اندازه‌گیری (trade-off بین سرعت و دقت)
- برهم‌کنش ناخواسته‌ی کیوبیت‌ها در سیستم‌های چندکیوبیتی

یکی از روش‌های کلاسیک برای کاهش خطای readout، بهینه‌سازی شکل پالس‌های اندازه‌گیری یا Pulse Shaping است. در این رویکرد، به‌جای استفاده از پالس‌های ساده‌ی مربعی، از پالس‌هایی با پوش زمانی مهندسی‌شده (مانند Gaussian یا DRAG-like) استفاده می‌شود.

اهداف اصلی Shaping Pulse در readout عبارت‌اند از:

- افزایش تفکیک‌پذیری سیگنال‌های I, Q برای حالت‌های مختلف کیوبیت

- کاهش اثرات گذرای ناخواسته و ringing در تشدیدگر

- بهینه‌سازی زمان اندازه‌گیری بدون افزایش نویز

در بسیاری از سامانه‌ها، پارامترهای shaping pulse (دامنه، پهنای و فاز) به‌صورت تجربی یا با روش‌های بهینه‌سازی عددی تنظیم می‌شوند. با این حال، این روش‌ها معمولاً بهینه‌سازی موضعی ارائه می‌دهند و در حضور نویز و تغییرات زمانی سیستم، عملکرد محدودی دارند.

ایده‌ی اصلی این است که به‌جای تعریف مرزهای تصمیم‌گیری ساده (مانند threshold خطی در صفحه‌ی I, Q)، از مدل‌هایی استفاده شود که بتوانند مرزهای غیرخطی و پیچیده را یاد بگیرند.

در این روش‌ها، داده‌های آموزشی شامل سیگنال‌های readout ثبت‌شده برای حالت‌های معلوم کیوبیت هستند. مدل یادگیری ماشین با این داده‌ها آموزش می‌بیند تا احتمال تعلق هر سیگنال به حالت $|0\rangle$ یا $|1\rangle$ را تخمین بزند.

یکی از رویکردهای پیشرفته، ترکیب shaping pulse و یادگیری ماشین است. در این چارچوب، شکل پالس به‌گونه‌ای طراحی می‌شود که اطلاعات حداکثری در سیگنال readout ایجاد کند و سپس الگوریتم یادگیری ماشین این اطلاعات را به‌صورت بهینه استخراج می‌نماید.

به‌عنوان مثال:

- استفاده از های‌پالس pulse مهندسی‌شده برای افزایش فاصله‌ی توزیع‌های I, Q

- استفاده از شبکه‌های عصبی برای تحلیل کل تایم‌تریس سیگنال

این ترکیب می‌تواند منجر به بهبود قابل توجه fidelity خوانش، حتی در شرایطی شود که محدودیت‌های سخت‌افزاری اجازه‌ی افزایش توان یا زمان اندازه‌گیری را نمی‌دهند.