

چکیده

در این پروژه، مسئله‌ی پیش‌بینی حالت کامل یک سامانه‌ی چهار کیوبیتی بر اساس داده‌های خوانش کوادریچر مورد بررسی قرار گرفته است. داده‌ها شامل اندازه‌گیری‌های مختلط برای هر کیوبیت بوده و هدف، نگاشت هر نمونه‌ی اندازه‌گیری به یکی از ۱۶ حالت ممکن سامانه‌ی چهار کیوبیتی است. با وجود استفاده از روش‌های مختلف یادگیری ماشین کلاسیک، مهندسی ویژگی و کرنل‌های الهام‌گرفته از نگاشت‌های کوانتومی نظیر ZZ feature map، دقت پیش‌بینی چندکلاسه در بهترین حالت به حدود ۳۸ تا ۳۹ درصد محدود شده است. در این گزارش، مسئله از دید فیزیکی و آماری تشریح شده، روش‌های پردازش داده و مدل‌سازی بررسی می‌شوند و در نهایت مسیرهای فیزیکی، آزمایشگاهی و الگوریتمی برای بهبود دقت مدل ارائه می‌گردد.

۱-۰ مقدمه و شرح مسئله

خوانش حالت کیوبیت‌ها یکی از چالش‌های اساسی در سامانه‌های محاسبات کوانتومی مبتنی بر پلتفرم‌هایی نظیر کیوبیت‌های ابررسانا یا یون‌های به‌دام‌افتاده است. در این سامانه‌ها، اطلاعات حالت کوانتومی به‌طور مستقیم قابل اندازه‌گیری نیست و از طریق فرآیندهای خوانش غیرمستقیم استخراج می‌شود. این فرآیندها معمولاً منجر به سیگنال‌هایی در فضای کوادریچر می‌شوند که به‌صورت نقاطی در صفحه‌ی مختلط (I, Q) نمایش داده می‌شوند.

در این تحقیق، داده‌های مربوط به چهار کیوبیت مورد بررسی قرار گرفته‌اند. هر نمونه‌ی داده شامل چهار عدد مختلط است که هر یک متناظر با خوانش یک کیوبیت می‌باشد. برچسب هر نمونه یکی از ۱۶ حالت ممکن $|q_4 q_3 q_2 q_1\rangle$ است. هدف اصلی، طراحی یک مدل طبقه‌بندی است که بتواند با دریافت این چهار خوانش مختلط، حالت کامل سامانه‌ی چهار کیوبیتی را پیش‌بینی کند.

۲-۰ ساختار داده‌ها و تحلیل آماری اولیه

هر مجموعه داده از ۱۶ فایل تشکیل شده است که هر فایل متناظر با یک حالت چهارکیوبیتی خاص می‌باشد. در هر فایل، برای هر کیوبیت ۱۰۰۰ نمونه‌ی اندازه‌گیری ثبت شده است. با ترکیب این داده‌ها، مجموعه داده‌ای شامل ۱۶۰۰۰ نمونه ایجاد شده است.

تحلیل‌های بصری اولیه شامل ترسیم نمودارهای پراکندگی در صفحه‌ی IQ، هیستوگرام‌ها و توابع توزیع تجمعی انجام شد. این تحلیل‌ها نشان داد که توزیع داده‌های مربوط به حالات مختلف به شدت هم‌پوشان هستند. حتی با تقریب توزیع‌ها به شکل گاوسی و نمایش بیضی‌های کوواریانس، جدایش خطی یا حتی غیرخطی ساده بین کلاس‌ها امکان‌پذیر نبود. این رفتار با گزارش‌های تجربی رایج در خوانش کیوبیت‌ها هم‌خوانی دارد.

۳-۰ مهندسی ویژگی و پیش‌پردازش داده

در مرحله‌ی مهندسی ویژگی، دو نمایش اصلی برای داده‌های مختلط در نظر گرفته شد. در نمایش نخست، هر عدد مختلط به دو مولفه‌ی حقیقی و موهومی تجزیه شد که منجر به بردار ویژگی ۸ بعدی می‌گردد. در نمایش دوم که به عنوان Angle Encoding شناخته می‌شود، هر عدد مختلط به دامنه و فاز متناظر آن نگاشت شد. این نمایش از نظر فیزیکی معنادارتر بوده و به‌ویژه در ترکیب با کرنل‌های مبتنی بر توابع تناوبی مزیت دارد.

به منظور کاهش اثر داده‌های پرت و ناپایداری آماری، روش‌های مختلف نرمال‌سازی بررسی شدند. نتایج نشان داد که استفاده از RobustScaler نسبت به StandardScaler برای داده‌های نویزی آزمایشگاهی مناسب‌تر است.

۴-۰ مدل‌سازی و الگوریتم‌های یادگیری ماشین

مدل پایه‌ی مورد استفاده، ماشین بردار پشتیبان (SVM) بود. در ابتدا، کرنل‌های استاندارد نظیر RBF برای طبقه‌بندی تک‌کیوبیتی و چندکلاسه مورد استفاده قرار گرفتند. در حالت تک‌کیوبیتی، دقت‌های نسبتاً

بالایی برای برخی کیوبیت‌ها به دست آمد، اما در حالت چندکلاسه، دقت به طور قابل توجهی کاهش یافت. به منظور لحاظ کردن هم‌بستگی‌های بین ویژگی‌ها، یک کرنل سفارشی الهام‌گرفته از ZZ feature map معرفی شد. این کرنل شامل ترم‌های تک‌ویژگی و ترم‌های جفتی بود که به صورت توابع کسینوسی تعریف می‌شدند. تنظیم پارامترهای این کرنل از طریق جستجوی شبکه‌ای انجام شد.

۵-۰ نتایج و محدودیت‌ها

بهترین دقت حاصل برای مسئله‌ی ۱۶ کلاسه حدود ۳۸ تا ۳۹ درصد بود. این نتیجه نشان می‌دهد که اگرچه کرنل‌های الهام‌گرفته از کوانتوم می‌توانند اطلاعات بیشتری از ساختار داده‌ها استخراج کنند، اما هم‌پوشانی ذاتی توزیع‌ها و نویز اندازه‌گیری محدودیت اصلی باقی می‌ماند.

۶-۰ مسیرهای پیشنهادی برای بهبود

از منظر فیزیکی و آزمایشگاهی، بهبود تفکیک‌پذیری خوانش، کاهش cross-talk و افزایش نسبت سیگنال به نویز می‌تواند نقش کلیدی ایفا کند. از منظر مدل‌سازی، استفاده از مدل‌های مولد، روش‌های ensemble و مدل‌های گراف‌ی پیشنهاد می‌شود. در نهایت، بهره‌گیری از الگوریتم‌های کوانتومی واقعی نظیر QSVM یا طبقه‌بندهای واریاسیونی کوانتومی می‌تواند مسیر آینده‌ی این تحقیق باشد.

۷-۰ تحلیل هم‌پوشانی ذاتی و وابستگی خوانش چندکیوبیتی

به منظور تشخیص این‌که محدودیت دقت مدل ناشی از هم‌پوشانی ذاتی توزیع‌های خوانش است یا وابستگی و cross-talk بین کیوبیت‌ها، یک تحلیل داده‌محور با الهام از معیارهای معرفی‌شده در مقاله‌ی Multiplexed qubit readout quality metric beyond assignment fidelity انجام شد. تأکید این تحلیل بر استفاده‌ی صرف از داده‌های موجود خوانش بوده و هیچ‌گونه دسترسی به پارامترهای فیزیکی آزمایش فرض نشده است.

۱-۷-۰ جدایش پذیری ذاتی تک کیوبیتی

در گام نخست، برای هر کیوبیت یک مدل طبقه بندی دودویی تنها بر اساس خوانش همان کیوبیت آموزش داده شد. دقت این مدل ها را می توان به عنوان سقف اطلاعاتی جدایش پذیری ذاتی هر کیوبیت در نظر گرفت. نتایج به صورت زیر به دست آمد:

کیوبیت	دقت جدایش ذاتی
کیوبیت ۱	۷۱۳.۰
کیوبیت ۲	۸۱۸.۰
کیوبیت ۳	۸۰۲.۰
کیوبیت ۴	۸۱۴.۰

این نتایج نشان می دهند که حتی در بهترین حالت و با استفاده از اطلاعات خوانش همان کیوبیت، خطای ذاتی قابل توجهی وجود دارد. اگر فرض شود خطاهای خوانش کیوبیت ها مستقل هستند، سقف دقت پیش بینی حالت چهار کیوبیتی را می توان به صورت تقریبی برابر حاصل ضرب دقت های تک کیوبیتی برآورد کرد که عددی در حدود ۳۸ درصد به دست می دهد. این مقدار با بهترین دقت مشاهده شده در مدل چند کلاسه هم خوانی دارد.

۲-۷-۰ تحلیل وابستگی بین کیوبیتی (Cross-talk)

در گام دوم، وابستگی خوانش کیوبیت i به حالت کیوبیت j بررسی شد. برای این منظور، توزیع خوانش کیوبیت i مشروط به $q_j = 0$ و $q_j = 1$ مقایسه گردید. معیارهایی نظیر جابه جایی میانگین و فاصله ی ماهالانوبیس بین این دو توزیع محاسبه شدند.

نتایج نشان دادند که عناصر روی قطر ماتریس وابستگی (یعنی $i = j$) به طور قابل توجهی بزرگ تر از عناصر خارج از قطر هستند، در حالی که وابستگی های بین کیوبیتی مقدار بسیار کوچکی دارند. اگرچه برخی از این وابستگی های ضعیف از نظر آماری معنی دار هستند، اما اندازه ی اثر آن ها از نظر فیزیکی ناچیز است. این موضوع نشان می دهد که cross-talk بین خوانش ها نقش غالبی در محدودیت دقت مدل ایفا نمی کند.

۳-۷-۰ نتیجه گیری تحلیلی

این تحلیل نشان می‌دهد که عامل اصلی محدودکننده دقت پیش‌بینی حالت چهارکیوبیتی، هم‌پوشانی ذاتی توزیع‌های خوانش تک‌کیوبیتی است، نه وابستگی شدید بین خوانش کیوبیت‌ها. بنابراین، افزایش قابل توجه دقت مدل تنها از طریق پیچیده‌تر کردن الگوریتم‌های یادگیری ماشین ممکن نیست و نیازمند بهبودهای فیزیکی در فرآیند خوانش و افزایش تفکیک‌پذیری اندازه‌گیری‌ها است.

۸-۰ دیکودر گاوسی بیزی (تحلیل تمایز درجه دوم)

به‌منظور به‌کارگیری یک رویکرد مدل‌محور متناسب با ماهیت آماری خوانش کیوبیت‌ها، روشی مبتنی بر مدل‌سازی مولد گاوسی و قانون بیز پیاده‌سازی و ارزیابی شد. این روش تحت عنوان Quadratic Discriminant Analysis (QDA) یا دیکودر گاوسی بیزی شناخته می‌شود و در بسیاری از کاربردهای خوانش کیوبیت به‌عنوان یک روش استاندارد مورد استفاده قرار می‌گیرد.

۱-۸-۰ انگیزه و هدف

در روش‌های تشخیصی معمول (مثل SVM)، به‌طور مستقیم توزیع شرطی برچسب به‌ازای ویژگی‌ها، یعنی $P(y | x)$ ، یادگیری می‌شود و مرز تصمیم به‌صورت هندسی برآورد می‌گردد. در مقابل، در رویکرد مولد گاوسی، توزیع داده به‌ازای هر حالت (کلاس) مدل می‌شود؛ یعنی $P(x | s)$ برای هر حالت s از ۱۶ حالت ممکن. سپس با به‌کارگیری قانون بیز و با فرض prior یکنواخت (یا برآوردشده از داده)، حالت به‌عنوان

$$\hat{s} = \arg \max_s P(x | s) P(s) = \arg \max_s P(x | s) \quad (1)$$

انتخاب می‌شود (در صورت یکنواخت بودن $P(s)$). مزیت این رویکرد آن است که ساختار نویز و کوواریانس واقعی هر کلاس به‌طور صریح در مدل وارد می‌شود و مرز تصمیم به‌صورت بیضی‌وارهای (quadratic) در فضای ویژگی شکل می‌گیرد، که با توزیع‌های گاوسی چندمتغیره هم‌خوانی بهتری دارد.

۲-۸-۰ فرض‌های مدل و فرم ریاضی

فرض می‌کنیم برای هر حالت $s \in \{0, 1, \dots, 15\}$ ، بردار ویژگی $x \in \mathbb{R}^8$ (شامل مولفه‌های حقیقی و موهومی چهار خوانش مختلط) از یک توزیع گاوسی چندمتغیره با میانگین μ_s و ماتریس کوواریانس Σ_s تبعیت می‌کند:

$$x | s \sim \mathcal{N}(\mu_s, \Sigma_s). \quad (۲)$$

به‌جای کار با احتمال مستقیم، از لگاریتم احتمال (log-likelihood) استفاده می‌کنیم که از نظر عددی پایدارتر است. برای یک نمونه x و کلاس s :

$$\log P(x | s) = -\frac{1}{2}(x - \mu_s)^\top \Sigma_s^{-1}(x - \mu_s) - \frac{1}{2} \log |\Sigma_s| + \text{const}. \quad (۳)$$

عبارت اول معادل منفی نصف فاصله‌ی ماحالانوبیس (مقیاس شده با Σ_s) و عبارت دوم مربوط به حجم بیضی کوواریانس است. در نهایت، کلاسی که مقدار $\log P(x | s) + \log P(s)$ را بیشینه می‌کند به‌عنوان پیش‌بینی انتخاب می‌شود؛ که با برآورد $P(s)$ از نسبت نمونه‌های هر کلاس در داده‌ی آموزش (prior) انجام می‌شود.

۳-۸-۰ پارامترهای مدل و منظم‌سازی

برای هر کلاس s ، پارامترهای μ_s و Σ_s به‌صورت تجربی از داده‌ی آموزش برآورد می‌شوند:

$$\hat{\mu}_s = \frac{1}{n_s} \sum_{i: y_i=s} x_i, \quad \hat{\Sigma}_s = \frac{1}{n_s - 1} \sum_{i: y_i=s} (x_i - \hat{\mu}_s)(x_i - \hat{\mu}_s)^\top, \quad (۴)$$

که n_s تعداد نمونه‌های کلاس s است. برای جلوگیری از وارون‌ناپذیری عددی یا تکی‌شدن Σ_s (به‌ویژه وقتی بعد ویژگی نسبت به تعداد نمونه زیاد است)، یک منظم‌ساز به صورت $\Sigma_s \leftarrow \Sigma_s + \varepsilon I$ با $\varepsilon = 10^{-6}$ اعمال شد.

در مرحله‌ی پیش‌بینی، به‌جای محاسبه‌ی صریح Σ_s^{-1} (که از نظر عددی ناپایدار است)، از حل دستگاه

خطی $\Sigma_s z = (x - \mu_s)$ با `np.linalg.solve` استفاده شد؛ به طوری که ترم درجه دوم در (۳) به صورت $-\frac{1}{2}(x - \mu_s)^T z$ محاسبه می شود. همچنین برای $\log |\Sigma_s|$ از `np.linalg.slogdet` استفاده شد تا از پایداری عددی در محدوده‌ی مقادیر بسیار کوچک یا بزرگ اطمینان حاصل شود.

۴-۸-۰ نرمال سازی ویژگی و Shrinkage

در پیاده سازی اولیه، دقت مدل گاوسی بیزی حدود 38,67% به دست آمد که با دقت مدل SVM قابل مقایسه بود. برای بهبود، دو تغییر اعمال شد:

۱. **نرمال سازی ویژگی:** اعمال `StandardScaler` روی داده های آموزش و آزمون تا هر ویژگی با میانگین صفر و واریانس واحد در فضای آموزش تبدیل شود. این کار فرض گاوسی را در فضای ویژگی متعادل تر می کند و پایداری عددی را افزایش می دهد.

۲. **Shrinkage کوواریانس:** در نسخه ی `sklearn` از پارامتر `reg_param` استفاده شد که ماتریس کوواریانس هر کلاس را به سمت یک ماتریس مشترک «جمع» می کند (`shrinkage`). این کار از `overfitting` و تکین شدن کوواریانس های کلاس هایی با نمونه کم جلوگیری می کند.

جستجوی شبکه ای روی `reg_param` در بازه ی $[0, 0,5]$ انجام شد. بهترین دقت در حدود `reg_param=0.30` حاصل شد و دقت نهایی به حدود 39,20% رسید؛ یعنی بهبودی در حد حدود نیم واحد درصد نسبت به حالت بدون `shrinkage` و نرمال سازی.

۵-۸-۰ تحلیل ماتریس آشفتگی

ماتریس آشفتگی (`confusion matrix`) مدل گاوسی بیزی نشان داد که بیشتر خطاها بین `state` های «همسایه» رخ می دهند؛ یعنی حالت هایی که در فاصله ی همینگ ۱ از یکدیگر قرار دارند (فقط در یک کیوبیت با هم تفاوت دارند). این موضوع با فرض فیزیکی خطای خوانش تک کیوبیتی (`bit flip`) سازگار است و نشان می دهد که مدل تا حدی ساختار خطا را درک می کند، اما به دلیل هم پوشانی زیاد توزیع ها در فضای هشت بعدی، جدایش کامل ۱۶ کلاس ممکن نیست.

۶-۸-۰ جمع‌بندی روش

روش دیکودر گاوسی بیزی (QDA) به صورت کامل پیاده‌سازی شد و با نرمال‌سازی و shrinkage اندکی دقت را بهبود بخشید. با این حال، به دلیل هم‌پوشانی ذاتی توزیع‌های خوانش و محدودیت اطلاعات در هشت بعد برای ۱۶ کلاس، افزایش چشمگیر دقت تنها با این مدل قابل انتظار نبود. این نتیجه با تحلیل قبلی مبنی بر غلبه‌ی محدودیت فیزیکی خوانش تک‌کیوبیتی بر محدودیت الگوریتم هم‌خوانی دارد. برای گزارش نهایی، کدهای مربوط به بارگذاری داده، تبدیل به ویژگی حقیقی هشت‌بعدی، برآورد میانگین و کوواریانس هر کلاس، تابع log-likelihood با solve و slogdet، و پیش‌بینی با بیشینه‌سازی امتیاز بیزی در نوت‌بوک پروژه موجود است.

۹-۰ مدل مخلوط گاوسی (Gaussian Mixture Model) برای

دیکودینگ چندحالت

۱-۹-۰ انگیزه و چارچوب روش

در ادامه‌ی رویکرد مولد گاوسی تک‌مدلی، (QDA) این فرض مورد بازبینی قرار گرفت که توزیع داده‌های خوانش هر حالت الزاماً تک‌قله‌ای (Unimodal) نیست. در سامانه‌های خوانش چندکیوبیتی، عواملی نظیر نویز تقویت‌کننده، تغییرات فاز، دریافت زمانی و نوسانات محیطی می‌توانند باعث ایجاد ساختارهای چندمدی در توزیع خوانش شوند. در چنین شرایطی، تقریب هر کلاس با یک توزیع گاوسی منفرد ممکن است ساده‌سازی بیش از حد باشد.

به منظور مدل‌سازی دقیق‌تر ساختار آماری داده‌ها، برای هر کلاس s از یک مدل مخلوط گاوسی استفاده شد:

$$P(x | s) = \sum_{k=1}^{K_s} \pi_{s,k} \mathcal{N}(x | \mu_{s,k}, \Sigma_{s,k}), \quad (5)$$

که در آن K_s تعداد مؤلفه‌های گاوسی کلاس s ، ضرایب $\pi_{s,k}$ وزن‌های مخلوط و $\mu_{s,k}$ و $\Sigma_{s,k}$ به‌ترتیب میانگین و کوواریانس مؤلفه‌ی k ام هستند. پارامترها با استفاده از الگوریتم بیشینه‌سازی امید ریاضی (Expectation-Maximization) برآورد شدند.

پس از برآورد مدل برای هر کلاس، پیش‌بینی مشابه حالت QDA از طریق بیشینه‌سازی لگاریتم احتمال بیزی انجام شد:

$$\hat{s} = \arg \max_s [\log P(x | s) + \log P(s)]. \quad (6)$$

۲-۹-۰ تنظیم تعداد مؤلفه‌ها

برای بررسی تأثیر پیچیدگی مدل، تعداد مؤلفه‌های مخلوط برای همه‌ی کلاس‌ها به‌صورت یکسان در بازه‌ی

$$K \in \{1, 2, 3, 4, 5\}$$

آزمایش شد. همچنین یک راهبرد تطبیقی بر اساس معیار اطلاعات بیزی (BIC) به‌کار گرفته شد که در آن برای هر کلاس، مقدار بهینه‌ی K_s در بازه‌ی فوق انتخاب می‌شد.

۳-۹-۰ نتایج عددی

دقت مدل برای مقادیر مختلف تعداد مؤلفه‌ها به‌صورت زیر به‌دست آمد:

تعداد مؤلفه‌ها	دقت
$K = 1$	38.70%
$K = 2$	37.60%
$K = 3$	37.45%
$K = 4$	36.08%
$K = 5$	35.65%

در حالت انتخاب تطبیقی مبتنی بر BIC نیز دقت نهایی برابر با 38.25% به دست آمد. در این حالت، برخی کلاس‌ها به صورت بهینه با دو مؤلفه و برخی با یک مؤلفه مدل شدند، اما این افزایش انعطاف‌پذیری منجر به بهبود معنادار دقت نشد.

۴-۹-۰ تحلیل نتایج

نتایج نشان می‌دهد که افزایش تعداد مؤلفه‌های گاوسی نه تنها باعث بهبود دقت نشد، بلکه در مقادیر بزرگ‌تر K موجب کاهش عملکرد نیز گردید. این رفتار را می‌توان از چند منظر تفسیر کرد:

۱. ماهیت تقریباً تک‌مدی توزیع‌ها: تحلیل‌های بصری پیشین نشان می‌دهد که توزیع خوانش هر حالت در فضای ویژگی هشت‌بعدی تا حد زیادی تک‌مدی است. بنابراین، مدل تک‌گاوسی (QDA) تقریب مناسبی ارائه می‌دهد و افزایش پیچیدگی مدل ضروری نیست.

۲. بیش‌برازش آماری: با افزایش K ، تعداد پارامترهای مدل به‌طور چشمگیری افزایش می‌یابد (به‌ویژه در حضور کوواریانس کامل). این امر می‌تواند به بیش‌برازش داده‌ی آموزش و کاهش تعمیم‌پذیری در داده‌ی آزمون منجر شود.

۳. غلبه‌ی هم‌پوشانی بین‌کلاسی: مهم‌ترین عامل محدودکننده دقت، هم‌پوشانی ذاتی بین توزیع‌های کلاس‌های مختلف است. افزودن مؤلفه‌های بیشتر درون هر کلاس نمی‌تواند این هم‌پوشانی بین‌کلاسی را برطرف کند، زیرا منشأ آن ناشی از محدودیت تفکیک‌پذیری خوانش تک‌کیوبیتی است.

۵-۹-۰ جمع‌بندی

مدل مخلوط گاوسی به‌عنوان تعمیمی بر دیکودر گاوسی بیزی پیاده‌سازی و ارزیابی شد. نتایج نشان داد که بهترین عملکرد زمانی حاصل می‌شود که هر کلاس با یک مؤلفه‌ی گاوسی مدل شود (معادل QDA). افزایش تعداد مؤلفه‌ها نه تنها بهبود قابل توجهی ایجاد نکرد، بلکه در اغلب موارد موجب افت دقت گردید.

این نتیجه تأیید می‌کند که محدودیت عملکرد مدل بیش از آن‌که ناشی از ساده‌سازی توزیع درون‌کلاسی باشد، ناشی از هم‌پوشانی ذاتی توزیع‌های خوانش در بین کلاس‌های مختلف است. بنابراین، افزایش پیچیدگی مدل مولد در سطح کلاس نمی‌تواند به‌تنهایی منجر به جهش قابل توجه در دقت پیش‌بینی شود.

۱۰-۰ دیکودینگ مبتنی بر فاصله‌ی ماحالانوبیس

۱-۱۰-۰ انگیزه

با توجه به ماهیت تقریباً گاوسی داده‌های خوانش در فضای ویژگی هشت‌بعدی، این پرسش مطرح شد که آیا یک دیکودر ساده مبتنی بر فاصله‌ی ماحالانوبیس، بدون استفاده از لگاریتم احتمال کامل بیزی، می‌تواند عملکرد بهتری ارائه دهد یا خیر.

در این چارچوب، تصمیم‌گیری صرفاً بر اساس کمینه‌سازی فاصله‌ی آماری از مرکز هر کلاس انجام می‌شود:

$$d_M(x, \mu_s, \Sigma_s) = (x - \mu_s)^\top \Sigma_s^{-1} (x - \mu_s) \quad (V)$$

که در آن μ_s و Σ_s به‌ترتیب میانگین و کوواریانس کلاس s هستند.

۲-۱۰-۰ Mahalanobis با کوواریانس کامل برای هر کلاس

در این نسخه، برای هر یک از ۱۶ حالت چهارکیوبیتی، میانگین و کوواریانس کامل به‌صورت مستقل برآورد شد. پیش‌بینی با انتخاب کلاسی که کمترین فاصله‌ی ماحالانوبیس را دارد انجام گردید.

دقت حاصل برابر بود با:

37.03%

این مقدار اندکی کمتر از دقت QDA کامل بود، که می‌تواند ناشی از حذف ترم $\log |\Sigma_s|$ در تابع تصمیم باشد.

۳-۱۰-۰ Mahalanobis با کوواریانس مشترک (فرض LDA)

به‌منظور کاهش نویز تخمین کوواریانس، یک ماتریس کوواریانس مشترک از کل داده‌ی آموزش برآورد شد و برای همه‌ی کلاس‌ها مورد استفاده قرار گرفت. در این حالت، مرز تصمیم خطی در فضای ویژگی شکل می‌گیرد.

دقت مدل در این حالت برابر بود با:

$$38.66\%$$

بهبود مشاهده‌شده نسبت به حالت کوواریانس کامل، نشان می‌دهد که کاهش واریانس تخمین کوواریانس می‌تواند نقش مثبتی در تعمیم‌پذیری مدل داشته باشد.

۴-۱۰-۰ منظم‌سازی کوواریانس (Ledoit–Wolf Shrinkage)

برای بررسی اثر منظم‌سازی آماری، از تخمین‌گر Ledoit–Wolf جهت برآورد کوواریانس مشترک استفاده شد:

$$\Sigma_{\text{shrink}} = (1 - \alpha)\Sigma + \alpha I \quad (۸)$$

ضریب بهینه‌ی برآوردشده:

$$\alpha = 0.0052$$

دقت حاصل در این حالت برابر با:

$$38.66\%$$

مقدار کوچک α نشان می‌دهد که ماتریس کوواریانس تجربی از قبل خوش شرط بوده و نیاز به منظم‌سازی قابل توجهی نداشته است.

۱۱-۰ دیکودینگ ساختار محور بیت به بیت

۱-۱۱-۰ انگیزه

در تمام روش‌های پیشین، مسئله به صورت یک طبقه‌بندی مستقیم ۱۶ کلاسه مدل‌سازی شده بود. با توجه به ساختار فیزیکی مسئله که در آن حالت کلی سامانه برابر با ترکیب چهار بیت مستقل است، رویکردی ساختار محور مورد بررسی قرار گرفت.

در این روش، به جای پیش‌بینی مستقیم ۱۶ حالت، برای هر کیوبیت یک مدل دودویی مستقل آموزش داده شد:

$$P(q_i = 0 \mid x), \quad P(q_i = 1 \mid x)$$

و در نهایت، چهار بیت پیش‌بینی شده ترکیب شده و حالت کامل بازسازی گردید.

۲-۱۱-۰ نتایج دیکودینگ بیت به بیت

دقت بازسازی حالت کامل چهار کیوبیتی در این روش برابر بود با:

$$38.69\%$$

برای تحلیل دقیق‌تر، دقت هر کیوبیت به صورت مستقل نیز محاسبه شد:

کیوبیت	دقت
کیوبیت ۱	۲۲٪.۷۱
کیوبیت ۲	۷۸٪.۸۲
کیوبیت ۳	۳۱٪.۸۰
کیوبیت ۴	۷۲٪.۸۱

این نتایج نشان می‌دهد که دقت کلی ۱۶ حالت به صورت غیرخطی از دقت‌های تک‌کیوبیتی تأثیر می‌پذیرد. در صورت فرض استقلال خطاها، حاصل ضرب تقریبی دقت‌های بیت‌ها مقداری نزدیک به دقت مشاهده‌شده برای حالت کامل به دست می‌دهد.

۱۲-۰ مقایسه‌ی کمی روش‌های ارزیابی شده

روش	دقت
SVM (پایه)	~ 38%
QDA (کوواریانس کامل)	۶۷٪.۳۸
Shrinkage + QDA	۲۰٪.۳۹
GMM (بهترین حالت $K = 1$)	۷۰٪.۳۸
Mahalanobis (کوواریانس کامل)	۰۳٪.۳۷
Mahalanobis (کوواریانس مشترک)	۶۶٪.۳۸
Ledoit-Wolf + Mahalanobis	۶۶٪.۳۸
دیکودینگ بیت‌به‌بیت گاوسی	۶۹٪.۳۸

۱۳-۰ تحلیل مرحله‌ای و وضعیت فعلی

مجموعه‌ی گسترده‌ای از روش‌های مولد و فاصله‌محور مبتنی بر فرض گاوسی مورد بررسی قرار گرفت. با وجود تفاوت در پیچیدگی مدل‌ها (از QDA کامل تا مدل مخلوط گاوسی و دیکودینگ ساختارمحور)،

دقت نهایی در بازه‌ای محدود (تقریباً ۳۷ تا ۳۹ درصد) باقی ماند.

این همگرایی عملکردی می‌تواند نشان‌دهنده‌ی وجود یک محدودیت آماری در نمایش فعلی ویژگی‌ها باشد. با این حال، در این مرحله نتیجه‌گیری قطعی انجام نمی‌شود، زیرا هنوز مسیرهای مدل‌سازی غیرخطی، مهندسی ویژگی پیشرفته و ترکیب مدل‌ها مورد بررسی کامل قرار نگرفته‌اند.

۱۴-۰ جمع‌بندی

در این گزارش، مسئله‌ی پیش‌بینی حالت کامل چهار کیوبیت با استفاده از داده‌های خوانش کوادریچر بررسی شد. نتایج نشان داد که محدودیت دقت مدل بیش از آنکه ناشی از ضعف الگوریتم‌های یادگیری ماشین باشد، ریشه در ماهیت فیزیکی فرآیند اندازه‌گیری دارد. مسیرهای پیشنهادی ارائه‌شده می‌توانند مبنایی برای ادامه‌ی تحقیق در حوزه‌های آزمایشگاهی و الگوریتمی باشند.