

کاهش خطای کوانتومی (خوانش)

هدف این پژوهش اعمال روش های مختلف یادگیری ماشین (کلاسیک و کوانتومی) برای کاهش خطای خوانش کیوبیت ها است. در حال حاضر تمرکز بر یک دیتاست حاصل از خوانش چهار کیوبیت در فضای کوادریچر- فاز (Q-I) است. داده ها در قالب ۱۶ فایل متنی با نام هایی از 0000.txt تا 1111.txt ارائه شده است. نام فایل ها به عنوان برچسب کلاس (label) استفاده شده و هر فایل شامل چهار خط (چهار کیوبیت) و هزار مقدار مختلط برای هر خط است. روش های آموزش ماشین و بهبود مدل که در این جا به کار می بریم باید برای تعداد بیشتر کیوبیت قبل تعمیم باشد. چرا که کامپیوترهای کوانتومی شامل ده ها کیوبیت می شوند و روند کاهش خطا در خوانش کیوبیت ها جزء بسیار مهم در حوزه سامانه های پردازش کیوبیتی است. با وجود استفاده از روش های مختلف یادگیری ماشین کلاسیک، مهندسی ویژگی و کرنل های الهام گرفته از نگاشت های کوانتومی نظیر ZZ feature map، دقت پیش بینی چندکلاسه در بهترین حالت به حدود ۳۸ تا ۳۹ درصد محدود شده است.

این گزارش شامل مراحل تحلیل داده، اعمال مدل های مختلف، مهندسی داده، بررسی نتایج و در نهایت طرح پیشنهادات و راهکارهای مرتبط است.

شرح مسئله

خوانش حالت کیوبیت های یکی از چالش های اساسی در سامانه های محاسبات کوانتومی مبتنی بر پلتفرم هایی نظیر کیوبیت های ابررسانا یا یون های به دام افتاده است. در این سامانه ها، اطلاعات حالت کوانتومی به طور مستقیم قابل اندازه گیری نیست و از طریق فرآیندهای خوانش غیرمستقیم استخراج می شود.

در بسیاری از پلتفرم ها (به ویژه کیوبیت های ابررسانا)، خوانش کیوبیت در dispersive regime

انجام می‌شود. در این حالت، حالت کیوبیت باعث تغییر کوچکی در فرکانس تشدیدگر می‌شود و این تغییر از طریق اندازه‌گیری سیگنال‌های I و Q (مولفه‌های درفاز و درتعامد) استخراج می‌گردد.

مهم‌ترین منابع خطای readout عبارت‌اند از:

- نویز تقویت‌کننده‌ها و زنجیره‌ی اندازه‌گیری
- هم‌پوشانی توزیع آماری سیگنال‌های مربوط به حالت‌های $|0\rangle$ و $|1\rangle$
- محدودیت‌های زمانی در اندازه‌گیری (trade-off بین سرعت و دقت)
- برهم‌کنش ناخواسته‌ی کیوبیت‌ها در سیستم‌های چندکیوبیتی

این فرآیندهای اندازه‌گیری معمولاً منجر به سیگنال‌هایی در فضای کوادریچر می‌شوند که به صورت نقاطی در صفحه‌ی مختلط (I, Q) نمایش داده می‌شوند.


در این تحقیق، داده‌های مربوط به چهار کیوبیت مورد بررسی قرار گرفته‌اند. هر نمونه‌ی داده شامل چهار عدد مختلط است که هر یک متناظر با خوانش یک کیوبیت می‌باشد. برچسب هر نمونه یکی از ۱۶ حالت ممکن $|q_4 q_3 q_2 q_1\rangle$ است. هدف اصلی، طراحی یک مدل طبقه‌بندی است که بتواند با دریافت این چهار خوانش مختلط، حالت کامل سامانه‌ی چهار کیوبیتی را پیش‌بینی کند.

در جدول ۱ مقایسه‌ای بین روش‌های مدل‌سازی که در این پژوهش به کار رفت به صورت مختصر به صورت مقایسه‌ای آورده شده است.

ساختار داده‌ها و تحلیل آماری اولیه

هر مجموعه‌داده از ۱۶ فایل تشکیل شده است که هر فایل متناظر با یک حالت چهارکیوبیتی خاص می‌باشد. در هر فایل، برای هر کیوبیت ۱۰۰۰ نمونه‌ی اندازه‌گیری ثبت شده است. با ترکیب این داده‌ها، مجموعه‌داده‌ای شامل ۱۶۰۰۰ نمونه ایجاد شده است.

تحلیل‌های بصری اولیه شامل ترسیم نمودارهای پراکندگی در صفحه‌ی IQ ، هیستوگرام‌ها و توابع توزیع تجمعی انجام شد. این تحلیل‌ها نشان داد که توزیع داده‌های مربوط به حالات مختلف به شدت هم‌پوشان هستند. حتی با تقریب توزیع‌ها به شکل گاوسی و نمایش بیضی‌های کوواریانس، جدایش



شکل ۱: یک نمونه از سیگنال‌های خوانش در صفحه‌ی I, Q (اندازه‌گیری برای کیوبیت چهارم). هم‌پوشانی توزیع آماری نقاط متناظر با حالت‌های $|0\rangle$ و $|1\rangle$ یکی از منابع اصلی خطای readout است.

خطی یا حتی غیرخطی ساده بین کلاس‌ها امکان‌پذیر نبود (شکل ۲). این رفتار با گزارش‌های تجربی رایج در خوانش کیوبیت‌ها هم‌خوانی دارد.

مدل‌سازی و الگوریتم‌های یادگیری ماشین

مهندسی ویژگی و پیش‌پردازش داده‌ها

در مرحله‌ی مهندسی ویژگی، دو نمایش اصلی برای داده‌های مختلط در نظر گرفته شد. در نمایش نخست، هر عدد مختلط به دو مولفه‌ی حقیقی و موهومی تجزیه شد که منجر به بردار ویژگی ۸ بعدی می‌گردد. در نمایش دوم که به‌عنوان Angle Encoding شناخته می‌شود، هر عدد مختلط به دامنه و فاز

جدول ۱: مقایسه‌ی روش‌های متداول یادگیری ماشین برای کاهش خطای readout کیوبیت‌ها


روش	نوع الگوریتم	ویژگی‌های ورودی	مزایا و کاربردها
Thresholding کلاسیک	تصمیم‌گیری خطی	نقطه‌ی انتهایی I, Q	ساده و سریع، ولی دقت محدود در حضور نویز
Re- Logistic gression	یادگیری نظارت‌شده (خطی)	I, Q یا ویژگی‌های استخراج‌شده	بهبود نسبت به thresh-old، تفسیرپذیر
SVM با کرنل غیرخطی	یادگیری نظارت‌شده	I, Q یا features Boxcar	مرز تصمیم‌گیری غیرخطی، دقت بالا برای داده‌های نویزی
شبکه کم عمق عصبی	یادگیری عمیق	بردار ویژگی یا تایم‌تریس کوتاه	انعطاف‌پذیر، مناسب برای readout سریع
شبکه‌های زمانی (RNN / CNN)	مدل مبتنی بر زمان	کل تایم‌تریس $I(t), Q(t)$	استخراج اطلاعات حداکثری، fidelity بالا
روش‌های تطبیقی آنلاین	یادگیری تدریجی	داده‌های به‌روز readout	مقاوم در برابر drift و تغییرات سیستم

متناظر آن نگاشت شد. این نمایش از نظر فیزیکی معنادارتر بوده و به‌ویژه در ترکیب با کرنل‌های مبتنی بر توابع تناوبی مزیت دارد.

به‌منظور کاهش اثر داده‌های پرت و ناپایداری آماری، روش‌های مختلف نرمال‌سازی بررسی شدند. نتایج نشان داد که استفاده از RobustScaler نسبت به StandardScaler برای داده‌های نویزی آزمایشگاهی مناسب‌تر است.

در گام نخست، برای هر کیوبیت یک مدل طبقه‌بندی دودویی تنها بر اساس خوانش همان کیوبیت آموزش داده شد. دقت این مدل‌ها را می‌توان به‌عنوان سقف اطلاعاتی جدایش‌پذیری ذاتی هر کیوبیت در نظر گرفت. نتایج به‌صورت زیر به‌دست آمد:

کیوبیت	دقت جدایش ذاتی
کیوبیت ۱	71.3%
کیوبیت ۲	81.8%
کیوبیت ۳	80.2%
کیوبیت ۴	81.4%




شکل ۲: تقریب توزیع بیضی های گاوسی برای کیوبیت اول از دو کلاس خاص (0000.txt و 1101.txt) . همپوشی بین بیضی ها زیاد است که نشان دهنده چالش در پیش بینی کلاس ها است.

این نتایج نشان می دهند که حتی در بهترین حالت و با استفاده از اطلاعات خوانش همان کیوبیت، خطای ذاتی قابل توجهی وجود دارد. اگر فرض شود خطاهای خوانش کیوبیت ها مستقل هستند، سقف دقت پیش بینی حالت چهارکیوبیتی را می توان به صورت تقریبی برابر حاصل ضرب دقت های تک کیوبیتی برآورد کرد که عددی در حدود ۳۸ درصد به دست می دهد؛

$$71.3\% \times 81.8\% \times 80.2\% \times 81.4\% \simeq 38\%$$

این مقدار با بهترین دقت مشاهده شده در مدل چندکلاسه هم خوانی دارد.

مدل های آموزش ماشین



شکل ۳: مدل آموزش دو دویی تنها بر اساس خوانش تک کیوبیت.

مدل پایه‌ی مورد استفاده، ماشین بردار پشتیبان (SVM) بود. در ابتدا، کرنل‌های استاندارد نظیر RBF برای طبقه‌بندی تک کیوبیتی و چندکلاسه مورد استفاده قرار گرفتند. در حالت تک کیوبیتی، دقت‌های نسبتاً بالایی برای برخی کیوبیت‌ها به دست آمد، اما در حالت چندکلاسه، دقت به طور قابل توجهی کاهش یافت. به منظور لحاظ کردن هم‌بستگی‌های بین ویژگی‌ها، یک کرنل سفارشی الهام گرفته از ZZ feature map معرفی شد. این کرنل شامل ترم‌های تک ویژگی و ترم‌های جفتی بود که به صورت توابع کسینوسی تعریف می‌شدند. تنظیم پارامترهای این کرنل از طریق جستجوی شبکه‌ای انجام شد. نتایج حاصل از این مدل برای کیوبیت اول در شکل ۴ نمایش داده شده است.


در گام دوم، وابستگی خوانش کیوبیت i به حالت کیوبیت j بررسی شد. برای این منظور، توزیع خوانش کیوبیت i مشروط به $q_j = 0$ و $q_j = 1$ مقایسه گردید. معیارهایی نظیر جابه‌جایی میانگین و فاصله‌ی ماحالانوبیس بین این دو توزیع محاسبه شدند.

نتایج نشان دادند که عناصر روی قطر ماتریس وابستگی (یعنی $i = j$) به طور قابل توجهی بزرگ‌تر از عناصر خارج از قطر هستند، در حالی که وابستگی‌های بین کیوبیتی مقدار بسیار کوچکی دارند. اگرچه برخی از این وابستگی‌های ضعیف از نظر آماری معنی دار هستند، اما اندازه‌ی اثر آن‌ها از نظر فیزیکی ناچیز است. این موضوع نشان می‌دهد که cross-talk بین خوانش‌ها نقش غالبی در محدودیت دقت مدل ایفا

```

Training SVM for qubit 1 using ZZ kernel...
Accuracy = 0.7147
Confusion matrix:
[[1685  315]
 [ 826 1174]]

```



شکل ۴: آموزش SVM با استفاده از کرنل کوانتمی zz feature برای پیش بینی کیوبیت اول.

نمی‌کند.

تحلیل هم‌پوشانی ذاتی و وابستگی خوانش چندکیوبیتی

به منظور تشخیص این‌که محدودیت دقت مدل ناشی از هم‌پوشانی ذاتی توزیع‌های خوانش است یا وابستگی و cross-talk بین کیوبیت‌ها، یک تحلیل داده‌محور با الهام از معیارهای معرفی شده در مقاله‌ی Multiplexed qubit readout quality metric beyond assignment fidelity انجام شد. تأکید این تحلیل بر استفاده‌ی صرف از داده‌های موجود خوانش بوده و هیچ‌گونه دسترسی به پارامترهای فیزیکی آزمایش فرض نشده است.

نتیجه‌گیری تحلیلی

در این گزارش، مسئله‌ی پیش‌بینی حالت کامل چهار کیوبیت با استفاده از داده‌های خوانش کوادریچر بررسی شد. نتایج نشان می‌دهد که عامل اصلی محدودکننده‌ی دقت پیش‌بینی حالت چهارکیوبیتی، هم‌پوشانی ذاتی توزیع‌های خوانش تک‌کیوبیتی است، نه وابستگی شدید بین خوانش کیوبیت‌ها. به بیان دیگر محدودیت دقت مدل بیش از آنکه ناشی از ضعف الگوریتم‌های یادگیری ماشین باشد، ریشه در ماهیت فیزیکی فرآیند اندازه‌گیری دارد. بنابراین، افزایش قابل توجه دقت مدل تنها از طریق پیچیده‌تر کردن الگوریتم‌های یادگیری ماشین ممکن نیست و نیازمند بهبودهای فیزیکی در فرآیند خوانش و افزایش تفکیک‌پذیری اندازه‌گیری‌ها است.